

Introducción al Aprendizaje Automático

Práctica 3 — Evaluación Honesta y Rigor Experimental

Sebastián Ventura Christian Luna
sventura@uco.es c.luna@uco.es

3er Curso Grado en Ingeniería Informática
Especialidad Computación
Escuela Politécnica Superior
(Universidad de Córdoba)

19 de marzo de 2026



Objetivos de la Práctica 3

¿Qué buscamos reforzar?

- Entender por qué una evaluación puede ser **engañosa**.
- Comparar **KFold** y **StratifiedKFold**.
- Ver el impacto del **desbalanceo de clases**.
- Detectar un caso de **data leakage**.

Objetivos de la Práctica 3

¿Qué buscamos reforzar?

- Entender por qué una evaluación puede ser **engañosa**.
- Comparar **KFold** y **StratifiedKFold**.
- Ver el impacto del **desbalanceo de clases**.
- Detectar un caso de **data leakage**.

Idea central

No basta con obtener una métrica alta: hay que comprobar que la evaluación sea **honesta**.

Material de partida y ejecución

Qué hay en la práctica


- Dataset sintético de **1000 pacientes**.
- **5 variables predictoras**.
- Problema muy desbalanceado:

clase positiva $\approx 2\%$

El problema: cuando la clase positiva casi no aparece

Situación

- La clase positiva es muy rara.
- Una partición aleatoria puede dejar muy pocos positivos en test.
- Entonces la evaluación deja de ser fiable.




El problema: cuando la clase positiva casi no aparece

Situación

- La clase positiva es muy rara.
- Una partición aleatoria puede dejar muy pocos positivos en test.
- Entonces la evaluación deja de ser fiable.

Consecuencia

Una Accuracy alta puede no significar que el modelo detecte bien la clase minoritaria.



Tarea 1: la lotería de la partición aleatoria

Qué hacer

- Aplicar `train_test_split` con partición 80/20.
- Repetir el proceso varias veces.
- Contar cuántos positivos aparecen en el test.


Qué debes observar

- ¿La composición del test cambia mucho?
- ¿Hay ejecuciones con muy pocos positivos?
- ¿Podemos confiar en una sola partición?

Tarea 1: la lotería de la partición aleatoria

Qué hacer

- Aplicar `train_test_split` con partición 80/20.
- Repetir el proceso varias veces.
- Contar cuántos positivos aparecen en el test.



KFold vs StratifiedKFold

KFold

- Divide en folds sin mirar la proporción de clases.
- En datos desbalanceados puede producir folds poco representativos.

StratifiedKFold

- Mantiene la proporción de clases en cada fold.
- Suele dar una evaluación más estable y justa.

KFold vs StratifiedKFold

KFold

- Divide en folds sin mirar la proporción de clases.
- En datos desbalanceados puede producir folds poco representativos.


StratifiedKFold

- Mantiene la proporción de clases en cada fold.
- Suele dar una evaluación más estable y justa.

Idea clave

La estratificación no mejora el modelo; mejora la **calidad de la evaluación**.

Tarea 2: comparar estabilidad



Tarea 2: comparar estabilidad

Experimento

- Ejecutar varias veces KFold.
- Ejecutar varias veces StratifiedKFold.
- Comparar **Accuracy**, **F1** y **desviación típica**.

Qué quiero que concluyas

- Qué método es más estable.
- Qué método depende menos del azar.
- Qué validación inspira más confianza.

Data Leakage: cuando el experimento está roto

Qué es

Hay **fuga de datos** cuando el modelo recibe información que no debería conocer en un caso real.

En esta práctica

Existe una **variable trampa** que filtra información del objetivo.

Data Leakage: cuando el experimento está roto

Qué es

Hay **fuga de datos** cuando el modelo recibe información que no debería conocer en un caso real.


En esta práctica

Existe una **variable trampa** que filtra información del objetivo.

Síntoma

El rendimiento se vuelve sospechosamente alto, incluso “demasiado bueno para ser verdad”.

Data Leakage: cuando el experimento está roto



Qué debe aparecer en tu PDF

Evidencias mínimas

- Resultado de varias particiones aleatorias.
- Comparativa entre KFold y StratifiedKFold.
- Comentario sobre la estabilidad de las métricas.
- Detección y explicación del **data leakage**.

Mensaje final

- Una métrica alta no siempre implica un buen modelo.
- La metodología importa tanto como el resultado.