



**ESCUELA POLITÉCNICA
SUPERIOR DE CÓRDOBA**
Universidad de Córdoba



Introducción al Aprendizaje Automático
Grado en Ingeniería Informática

CPráctica 4: Optimización por Matriz de Costes

Autores:

Alicia Muriel Fernández
Lucía Cañero Moslero

Abril, 2026



UNIVERSIDAD
DE
CÓRDOBA



Índice general

Índice de figuras	2
1. Práctica 4: Clasificación y el Valor del Error	3
0.1. Objetivo de la práctica	3
0.2. Descripción del problema	3
0.3. Tarea 1: Análisis con el umbral por defecto ($\tau = 0,5$)	4
0.4. Tarea 2: Estudio de probabilidades y umbrales	6
0.5. Tarea 3: Optimización del coste	7
0.6. Tarea 4: Curvas ROC y Precision-Recall	9
0.7. Decisión final de ingeniería	11
0.8. Conclusiones	11
Bibliografía	12

Índice de figuras

1.	Matriz de confusión para el umbral $\tau = 0,5$	4
2.	Coste total en función del umbral de decisión.	7
3.	Curva ROC del clasificador.	9
4.	Curva Precision-Recall del clasificador.	10

Capítulo 1

Práctica 4: Clasificación y el Valor del Error

0.1. Objetivo de la práctica

En esta práctica se entrena un clasificador probabilístico sencillo para un problema de detección de fraude y se analiza cómo el umbral de decisión afecta a los errores y al coste total. El objetivo no es únicamente medir el rendimiento predictivo del modelo, sino estudiar el impacto real de sus decisiones a partir de una matriz de costes.

0.2. Descripción del problema

Se trabaja con un problema de clasificación binaria:

- **Clase 0:** transacción normal.
- **Clase 1:** transacción fraudulenta.

En este contexto, los errores no tienen el mismo coste:

- **Falso Negativo (FN):** no detectar un fraude $\rightarrow 200$
- **Falso Positivo (FP):** bloquear una transacción legítima $\rightarrow 10$

Por tanto, la decisión final no debe evaluarse solo por el número de aciertos, sino por el coste económico asociado a los errores.

0.3. Tarea 1: Análisis con el umbral por defecto ($\tau = 0,5$)

0.3.1. Modelo utilizado

En esta práctica se ha utilizado una **Regresión Logística** como clasificador base. El modelo se ha entrenado con el conjunto de entrenamiento y se ha evaluado sobre el conjunto de prueba.

0.3.2. Matriz de confusión

A continuación se muestra la matriz de confusión obtenida usando el umbral estándar $\tau = 0,5$.




Figura 1: Matriz de confusión para el umbral $\tau = 0,5$.

A partir de esta matriz, se obtienen los siguientes valores:

- Verdaderos Positivos (TP): 16
- Verdaderos Negativos (TN): 501
- Falsos Positivos (FP): 1
- Falsos Negativos (FN): 22

0.3.3. Cálculo del coste total

El coste total se calcula mediante la expresión:

$$\text{Coste Total} = (FP \cdot 10) + (FN \cdot 200)$$

Sustituyendo los valores obtenidos:

$$\text{Coste Total} = (1 \cdot 10) + (22 \cdot 200) = 10 + 4400 = 4410$$

0.3.4. Interpretación

Comentario del alumno: *Explica aquí si el umbral por defecto de 0.5 parece razonable o no en este contexto. No te limites a decir si el modelo acierta mucho o poco; comenta especialmente si está controlando adecuadamente los errores más costosos.*

Guía para redactar:

- ¿El modelo comete muchos falsos negativos?
- ¿El coste total parece alto o bajo para este problema?
- ¿Usarías este umbral en un entorno real sin revisarlo?

El umbral por defecto de 0.5 no resulta adecuado para este problema. Con dicho umbral, el modelo solo identifica 16 de los 38 fraudes reales, dejando pasar 22 transacciones fraudulentas sin detectar. Esto supone que más de la mitad de los fraudes, exactamente el 57.9%, quedan sin clasificar correctamente. Esto es bastante grave dado que cada uno de esos errores tiene un coste de 200 para el banco.

En cuanto al coste total, los 4410 obtenidos están prácticamente dominados por los falsos negativos, que por sí solos generan $22 \times 200 = 4400$, es decir, el 99.7% del gasto total. Esto refleja claramente que el modelo está priorizando no molestar al cliente, evitando bloqueos innecesarios a costa de asumir un riesgo financiero bastante elevado.

Este umbral no debería utilizarse en un entorno real sin revisarlo. La asimetría de costes es determinante: un falso negativo es 20 veces más caro que un falso positivo, lo que justifica bajar el umbral de decisión para aumentar la sensibilidad del modelo. Aunque esto conlleve un mayor número de bloqueos a transacciones legítimas, el banco debería estar dispuesto a asumir ese inconveniente si a cambio se evitan pérdidas mucho mayores por fraudes no detectados.

0.4. Tarea 2: Estudio de probabilidades y umbrales

0.4.1. Análisis de distintos umbrales

En lugar de trabajar únicamente con la clase predicha, se han utilizado las probabilidades estimadas por el modelo para la clase positiva y se han evaluado distintos valores del umbral τ entre 0 y 1, en pasos de 0.05.

La siguiente tabla resume los resultados obtenidos para varios umbrales:

Tabla 1.1: Resumen de resultados para distintos umbrales.

Umbral	FP	FN	Coste Total ()
0.00	502	0	5020
0.05	112	9	2920
0.10	42	14	3220
0.15	22	15	3220
0.20	13	15	3130
$\vdots$	$\vdots$	$\vdots$	$\vdots$
0.50	1	22	4410
$\vdots$	$\vdots$	$\vdots$	$\vdots$
1.00	0	38	7600

0.4.2. Observaciones

Comentario del alumno: *Describe aquí cómo cambian los falsos positivos y los falsos negativos al mover el umbral.*

Guía para redactar:

- ¿Qué ocurre cuando el umbral baja?
- ¿Qué ocurre cuando el umbral sube?
- ¿Qué compromiso aparece entre FP y FN?

Cuando el umbral se reduce, el modelo tiende a etiquetar un mayor número de transacciones como fraudulentas. Esto queda patente al comparar $\tau = 0,5$ con $\tau = 0,05$: los falsos positivos se disparan de 1 a 112, pues numerosas transacciones legítimas cruzan esa barrera baja y quedan marcadas incorrectamente; al mismo tiempo, los falsos negativos caen de 22 a 9, ya que la mayor permisividad del modelo permite capturar más fraudes reales. En el caso extremo de $\tau = 0,00$, la totalidad de

las transacciones se etiqueta como fraude, lo que se traduce en 502 falsos positivos y ningún falso negativo, con un coste asociado de 5.020 explicado casi por completo por los errores sobre transacciones legítimas.

El comportamiento es el opuesto cuando el umbral crece: el modelo exige mayor certeza para considerar una transacción fraudulenta. Comparando $\tau = 0,5$ con $\tau = 0,95$, los falsos positivos prácticamente desaparecen, mientras que los falsos negativos se elevan de 22 a 37, dado que muchos fraudes reales presentan probabilidades moderadas y no alcanzan ese listón tan elevado. En el extremo $\tau = 1,00$, el modelo no detecta ningún fraude, dejando pasar los 38 casos reales y generando el coste máximo de 7.600.

Entre ambos tipos de error existe un compromiso inevitable: detectar más fraudes conlleva bloquear más operaciones legítimas, y reducir las interrupciones a clientes implica asumir un mayor número de fraudes sin detectar. Minimizar ambos errores al mismo tiempo no es factible.

0.5. Tarea 3: Optimización del coste

0.5.1. Gráfica de coste frente a umbral

La Figura 2 muestra la evolución del coste total en función del umbral de decisión.




Figura 2: Coste total en función del umbral de decisión.

0.5.2. Umbral óptimo

A partir de la gráfica y de la tabla anterior, el umbral que minimiza el coste total es:

$$\tau^* = 0,05$$

El coste total mínimo asociado es:

$$\text{Coste mínimo} = 2920 \text{ €}$$

0.5.3. Interpretación

Explica aquí si el umbral óptimo es mayor o menor que 0.5 y por qué ese valor tiene sentido en este problema.

Guía para redactar:

- ¿Por qué el mínimo no tiene por qué aparecer en 0.5?
- ¿Qué relación tiene ese valor con la diferencia de costes entre FP y FN?
- ¿Qué estrategia parece más razonable para el banco: conservadora o permisiva?

El análisis de la gráfica y la matriz de costes muestra que el umbral óptimo se encuentra en $\tau^* = 0,05$. Este valor es menor que el umbral estándar de 0.5. En la teoría de clasificación probabilística, se asume que todos los errores tienen el mismo peso cuando se utiliza el umbral de 0.5 de forma automática. Sin embargo, en este caso no es cierto. El motivo por el que el mínimo no se encuentra en 0.5 es que el umbral de clasificación no es una regla fija, sino una decisión que debe adaptarse al problema y al impacto real de los errores.

La justificación de este valor reside en la gran diferencia que existe entre los costes de los errores. Un falso negativo (FN, dejar pasar un fraude) supone una pérdida de 200 €, mientras que un falso positivo (FP, bloquear erróneamente una tarjeta legítima) solo cuesta 10 €.

Dado que el coste de ignorar una amenaza es 20 veces mayor, el modelo debe ser mucho más sensible. Al reducir el umbral a 0.05, se detectan más fraudes, pero también se acepta un aumento en los falsos positivos. Sin embargo, se reducen drásticamente los falsos negativos, que son los errores más costosos.

Por lo tanto, la estrategia más adecuada para el banco es adoptar una **política conservadora**. Es más eficiente desde el punto de vista económico y de riesgo detectar la mayor cantidad posible de fraudes, incluso si eso significa bloquear algunas transacciones legítimas. En definitiva, esta optimización demuestra que un modelo

no debe evaluarse solo por sus resultados teóricos, sino por el coste real y el impacto económico de las decisiones que provoca.

0.6. Tarea 4: Curvas ROC y Precision-Recall

0.6.1. Curva ROC

La Figura 3 muestra la curva ROC obtenida para el modelo.




Figura 3: Curva ROC del clasificador.

0.6.2. Curva Precision-Recall

La Figura 4 muestra la curva Precision-Recall del modelo.




Figura 4: Curva Precision-Recall del clasificador.

0.6.3. Discusión

Comentario del alumno: *Si el dataset está desbalanceado, razona cuál de las dos curvas resulta más útil para valorar la utilidad real del modelo en este problema.*

Guía para redactar:

- ¿Qué información aporta la curva ROC?
- ¿Qué información aporta la curva Precision-Recall?
- ¿Cuál refleja mejor el comportamiento sobre la clase minoritaria?

En situaciones donde el conjunto de datos está desbalanceado, como en la detección de fraude bancario, la curva de Precisión-Recuerdo es más informativa y realista que la curva ROC para evaluar la utilidad un modelo.

Por un lado, la curva ROC relaciona la Sensibilidad (Tasa de Verdaderos Positivos) con la Tasa de Falsos Positivos, proporcionando una visión global del clasificador. Sin embargo, en conjuntos de datos con muchos casos negativos (transacciones legítimas), el gran número de Verdaderos Negativos oculta el impacto real de los Falsos Positivos.

Como se observa en la Figura 3, el modelo parece muy bueno, con un Área Bajo la Curva (AUC) de 0.8442. Pero esto se debe a que el gran número de aciertos en la clase mayoritaria enmascara los errores.

Por el otro lado, la curva Precision-Recall se centra exclusivamente en la clase positiva. Esta gráfica no tiene en cuenta los resultados negativos verdaderos y evalúa

cómo se equilibran la capacidad del modelo para encontrar todas las amenazas reales y la certeza de que, cuando el sistema da una alerta, efectivamente se trata de un fraude.

En resumen, la curva Precision-Recall es la que refleja mejor el comportamiento sobre la clase minoritaria. Al mirar la Figura 4, vemos que la Precisión Media es de 0,6551. Esta gráfica muestra el problema real de usar este clasificador cuando las clases están desequilibradas.

La gráfica muestra que cuando se intenta aumentar el Recall o Sensibilidad, es decir, detectar todos los casos de fraude sin perder ninguno, la Precisión baja mucho. Esto sucede porque aparecen muchos falsos positivos.

0.7. Decisión final de ingeniería

Imaginando que formo parte del equipo técnico del banco, la política de decisión que recomendaría sería la siguiente:

[REDACTAR AQUÍ UNA PROPUESTA BREVE Y ARGUMENTADA]

Esta decisión se basa en:

- el coste asociado a los falsos positivos y falsos negativos;
- el umbral que minimiza el coste total;
- el equilibrio entre seguridad y molestias para el cliente;
- la interpretación conjunta de las curvas ROC y Precision-Recall.

0.8. Conclusiones

Comentario final del alumno: *Resume aquí qué has aprendido con esta práctica y explica por qué en clasificación no todos los errores valen lo mismo.*

Aspectos que conviene mencionar:

- que el umbral de decisión no es fijo ni universal;
- que cambiar el umbral modifica la relación entre FP y FN;
- que el contexto del problema debe influir en la evaluación;
- que una métrica general no siempre refleja el impacto real de un modelo.

Bibliografía

- [1] Sebastián Ventura and Christian Luna. Práctica 3 - evaluación honesta y rigor experimental (diapositivas), 2026. Asignatura: Introducción al Aprendizaje Automático. Accedido en marzo 2026.
- [2] Sebastián Ventura Soto. Tema 04 - ajuste fino y selección de modelos (diapositivas de teoría), 2026. Asignatura: Introducción al Aprendizaje Automático. Accedido en marzo 2026.
- [3] Sebastián Ventura Soto. Tema 07 - evaluación de clasificadores (diapositivas de teoría), 2026. Asignatura: Introducción al Aprendizaje Automático. Accedido en marzo 2026.
- [4] Sebastián Ventura Soto. Tema 05b - clasificación logística. (diapositivas de teoría), 2026. Asignatura: Introducción al Aprendizaje Automático. Accedido en marzo 2026.
- [5] Universidad de Córdoba. Guion práctica 3: Metodología de evaluación y rigor científico, 2026. Asignatura: Introducción al Aprendizaje Automático (3ª Ingeniería Informática). Accedido en marzo 2026.