ESCUELA POLITÉCNICA
SUPERIOR DE CÓRDOBA
Universidad de Córdoba

EPSC

Introducción al Aprendizaje Automático

Grado en Ingeniería Informática

Práctica 4: Optimización por Matriz de Costes

Autores:

Alicia Muriel Fernández
Lucía Cañero Moslero

Octubre, 2026

UNIVERSIDAD
D
CÓRDOBA

Índice general

Índice de figuras **2**

1. Práctica 4: Clasificación y el Valor del Error **3**
1. Objetivo de la práctica . . . 3
2. Descripción del problema . . . 3
3. Tarea 1: Análisis con el umbral por defecto ($\tau = 0{,}5$) . . . 4
   - 3.1. Modelo utilizado . . . 4
   - 3.2. Matriz de confusión . . . 4
   - 3.3. Cálculo del coste total . . . 5
   - 3.4. Interpretación . . . 5
4. Tarea 2: Estudio de probabilidades y umbrales . . . 5
   - 4.1. Análisis de distintos umbrales . . . 5
   - 4.2. Observaciones . . . 6
5. Tarea 3: Optimización del coste . . . 7
   - 5.1. Gráfica de coste frente a umbral . . . 7
   - 5.2. Umbral óptimo . . . 7
   - 5.3. Interpretación . . . 7
6. Tarea 4: Curvas ROC y Precision-Recall . . . 8
   - 6.1. Curva ROC . . . 8
   - 6.2. Curva Precision-Recall . . . 9
   - 6.3. Discusión . . . 9
7. Decisión final de ingeniería . . . 10
8. Conclusiones . . . 11

Bibliografía **12**

Índice de figuras

1. Matriz de confusión para el umbral $\tau = 0{,}5$. 4
2. Coste total en función del umbral de decisión. 7
3. Curva ROC del clasificador. 8
4. Curva Precision-Recall del clasificador. 9

Capítulo 1

Práctica 4: Clasificación y el Valor del Error

1. Objetivo de la práctica

En esta práctica se entrena un clasificador probabilístico sencillo para un problema de detección de fraude y se analiza cómo el umbral de decisión afecta a los errores y al coste total. El objetivo no es únicamente medir el rendimiento predictivo del modelo, sino estudiar el impacto real de sus decisiones a partir de una matriz de costes.

2. Descripción del problema

Se trabaja con un problema de clasificación binaria:

- **Clase 0**: transacción normal.
- **Clase 1**: transacción fraudulenta.

En este contexto, los errores no tienen el mismo coste:

- **Falso Negativo (FN)**: no detectar un fraude → 200
- **Falso Positivo (FP)**: bloquear una transacción legítima → 10

Por tanto, la decisión final no debe evaluarse solo por el número de aciertos, sino por el coste económico asociado a los errores.

3. Tarea 1: Análisis con el umbral por defecto ($\tau = 0{,}5$)

3.1. Modelo utilizado

En esta práctica se ha utilizado una **Regresión Logística** como clasificador base. El modelo se ha entrenado con el conjunto de entrenamiento y se ha evaluado sobre el conjunto de prueba.

3.2. Matriz de confusión

A continuación se muestra la matriz de confusión obtenida usando el umbral estándar $\tau = 0{,}5$.

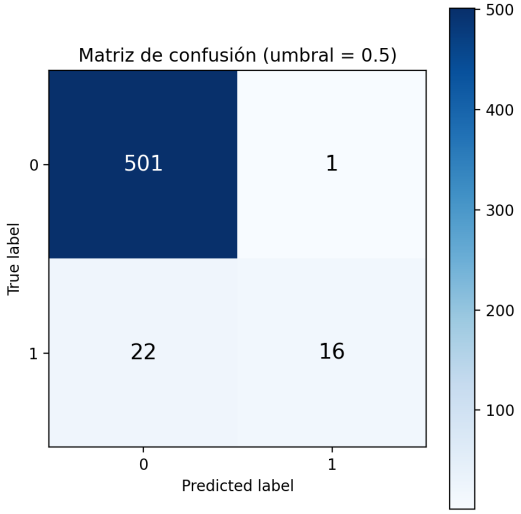


Figura 1: Matriz de confusión para el umbral $\tau = 0{,}5$.

A partir de esta matriz, se obtienen los siguientes valores:

- Verdaderos Positivos (TP): `16`
- Verdaderos Negativos (TN): `501`
- Falsos Positivos (FP): `1`
- Falsos Negativos (FN): `22`

3.3. Cálculo del coste total

El coste total se calcula mediante la expresión:

$$\text{Coste Total} = (FP \cdot 10) + (FN \cdot 200)$$

Sustituyendo los valores obtenidos:

$$\text{Coste Total} = (1 \cdot 10) + (22 \cdot 200) = 10+4400 = 4410$$

3.4. Interpretación

El umbral por defecto de 0.5 no es adecuado para este problema. Con dicho umbral, el modelo solo identifica 16 de los 38 fraudes reales, dejando pasar 22 transacciones fraudulentas sin detectar. Esto supone que más de la mitad de los fraudes, exactamente el 57.9 %, quedan sin clasificar correctamente. Esto es un gran problema dado que cada uno de esos errores tiene un coste de 200 para el banco.

En cuanto al coste total, los 4410 obtenidos están dominados por los falsos negativos, que por sí solos generan 22x200=4400, es decir, el 99.7 % del gasto total. Esto refleja claramente que el modelo está priorizando no molestar al cliente, evitando bloqueos innecesarios a costa de asumir un riesgo financiero bastante elevado.

Este umbral no debería utilizarse en un entorno real sin revisarlo. La asimetría de costes es determinante: un falso negativo es 20 veces más caro que un falso positivo, lo que justifica bajar el umbral de decisión para aumentar la sensibilidad del modelo. Aunque esto conlleve un mayor número de bloqueos a transacciones legítimas, el banco debería estar dispuesto a asumir ese inconveniente si a cambio se evitan pérdidas mucho mayores por fraudes no detectados.

4. Tarea 2: Estudio de probabilidades y umbrales

4.1. Análisis de distintos umbrales

En lugar de trabajar únicamente con la clase predicha, se han utilizado las probabilidades estimadas por el modelo para la clase positiva y se han evaluado distintos valores del umbral τ entre 0 y 1, en pasos de 0.05.

La siguiente tabla resume los resultados obtenidos para varios umbrales:

Tabla 1.1: Resumen de resultados para distintos umbrales.

Umbral	**FP**	**FN**	**Coste Total ()**
0.00	502	0	5020
0.05	112	9	2920
0.10	42	14	3220
0.15	22	15	3220
0.20	13	15	3130
⋮	⋮	⋮	⋮
0.50	1	22	4410
⋮	⋮	⋮	⋮
1.00	0	38	7600

4.2. Observaciones

Cuando el umbral se reduce, el modelo tiende a etiquetar un mayor número de transacciones como fraudulentas. Por ejemplo, si comparamos un umbral de $\tau = 0{,}5$ con uno de $\tau = 0{,}05$: vemos que los falsos positivos se disparan de 1 a 112. Esto significa que numerosas transacciones legítimas se marcan incorrectamente como fraudulentas. Al mismo tiempo, los falsos negativos disminuyen de 22 a 9, esto se debe a que el modelo se vuelve más permisivo y puede detectar más fraudes reales. En el caso extremo de $\tau = 0{,}00$, todas las transacciones se etiquetan como fraude, lo que genera 502 falsos positivos y ningún falso negativo, con un coste asociado de 5.020.

Sin embargo, cuando el umbral aumenta: el modelo exige mayor certeza para considerar una transacción fraudulenta. Si comparamos un umbral de $\tau = 0{,}5$ con uno de $\tau = 0{,}95$, vemos que los falsos positivos prácticamente desaparecen, mientras que los falsos negativos aumentan de 22 a 37, ya que el modelo se vuelve mucho más restrictivo, clasificando como normales aquellos fraudes cuyas probabilidades estimadas no logran superar este nuevo límite estricto. En el extremo de un umbral de $\tau = 1{,}00$, el modelo no detecta ningún fraude, dejando pasar los 38 casos reales y generando el coste máximo de 7.600.

Es importante destacar que existe un compromiso inevitable entre ambos tipos de error. Detectar más fraudes conlleva bloquear más operaciones legítimas, y reducir las interrupciones a clientes implica asumir un mayor número de fraudes sin detectar. No es posible minimizar ambos errores al mismo tiempo.

5. Tarea 3: Optimización del coste

5.1. Gráfica de coste frente a umbral

La Figura 2 muestra la evolución del coste total en función del umbral de decisión.

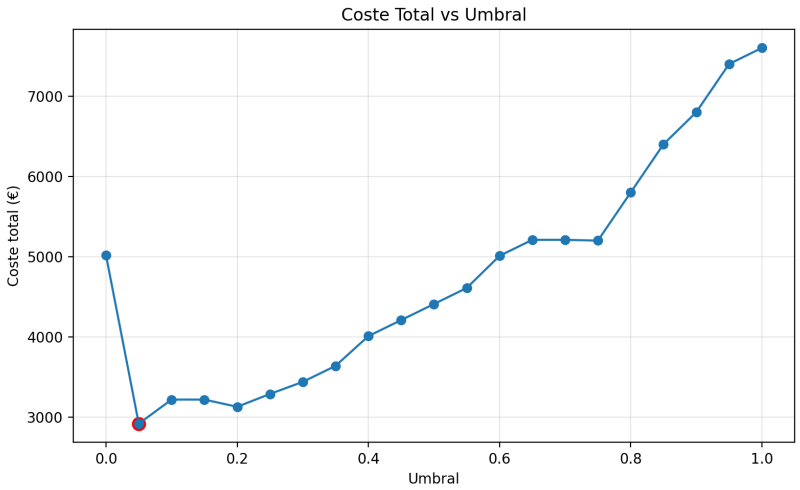


Figura 2: Coste total en función del umbral de decisión.

5.2. Umbral óptimo

A partir de la gráfica y de la tabla anterior, el umbral que minimiza el coste total es:

$$\tau^* = 0{,}05$$

El coste total mínimo asociado es:

$$\text{Coste mínimo} = 2920\ €$$

5.3. Interpretación

El análisis de la gráfica y la matriz de costes muestra que el umbral óptimo se encuentra en $\tau^* = 0{,}05$. Este valor es menor que el umbral estándar de 0.5. En la teoría de clasificación probabilística, se asume que todos los errores tienen el mismo peso cuando se utiliza el umbral de 0.5 de forma automática. Sin embargo, en este caso no es cierto. El motivo por el que el mínimo no se encuentra en 0.5 es que el umbral de clasificación no es una regla fija, sino una decisión que debe adaptarse al problema y al impacto real de los errores.

La justificación de este valor reside en la gran diferencia que existe entre los costes de los errores. Un falso negativo(FN, dejar pasar un fraude) supone una pérdida de 200 €, mientras que un falso positivo (FP, bloquear erróneamente una tarjeta legítima) solo cuesta 10 €.

Dado que el coste de ignorar una amenaza es 20 veces mayor, el modelo debe ser mucho más sensible. Al reducir el umbral a 0.05, se detectan más fraudes, pero también se acepta un aumento en los falsos positivos. Sin embargo, se reducen drásticamente los falsos negativos, que son los errores más costosos.

Por lo tanto, la estrategia más adecuada para el banco es adoptar una **política conservadora**. Es más eficiente desde el punto de vista económico y de riesgo detectar la mayor cantidad posible de fraudes, incluso si eso significa bloquear algunas transacciones legítimas. En definitiva, esta optimización demuestra que un modelo no debe evaluarse solo por sus resultados teóricos,sino por el coste real y el impacto económico de las decisiones que provoca.

6. Tarea 4: Curvas ROC y Precision-Recall

6.1. Curva ROC

La Figura 3 muestra la curva ROC obtenida para el modelo.

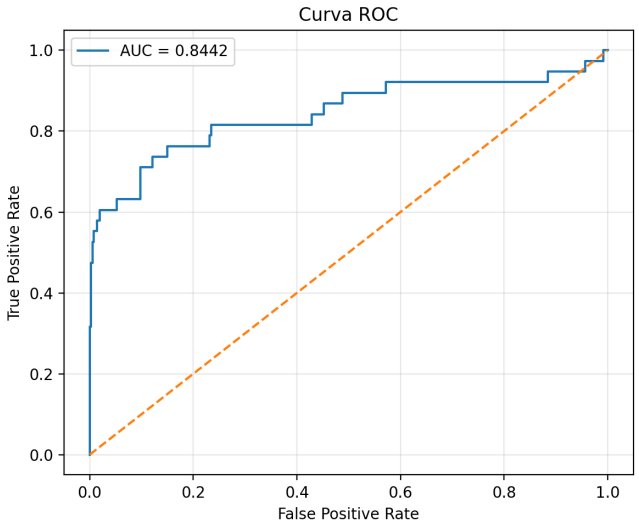


Figura 3: Curva ROC del clasificador.

6.2. Curva Precision-Recall

La Figura 4 muestra la curva Precision-Recall del modelo.

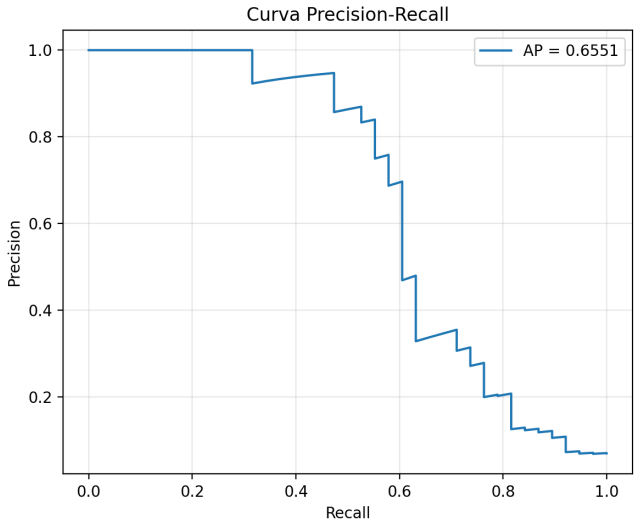


Figura 4: Curva Precision-Recall del clasificador.

6.3. Discusión

En situaciones donde el conjunto de datos está desbalanceado, como en la detección de fraude bancario, la curva de Precisión-Recuerdo es más informativa y realista que la curva ROC para evaluar la utilidad un modelo.

Por un lado, la curva ROC relaciona la Sensibilidad (Tasa de Verdaderos Positivos) con la Tasa de Falsos Positivos, proporcionando una visión global del clasificador. Sin embargo, en conjuntos de datos con muchos casos negativos (transacciones legítimas), el gran número de Verdaderos Negativos oculta el impacto real de los Falsos Positivos.

Como se observa en la Figura 3, el modelo parece muy bueno, con un Área Bajo la Curva (AUC) de 0.8442. Pero esto se debe a que el gran número de aciertos en la clase mayoritaria enmascara los errores.

Por el otro lado, la curva Precision-Recall se centra exclusivamente en la clase positiva. Esta gráfica no tiene en cuenta los resultados negativos verdaderos y evalúa cómo se equilibran la capacidad del modelo para encontrar todas las amenazas reales y la certeza de que, cuando el sistema da una alerta, efectivamente se trata de un fraude.

En resumen, la curva Precision-Recall es la que refleja mejor el comportamiento sobre la clase minoritaria. Al mirar la Figura 4, vemos que la Precisión Media es de

0,6551. Esta gráfica muestra el problema real de usar este clasificador cuando las clases están desequilibradas.

La gráfica muestra que cuando se intenta aumentar el Recall o Sensibilidad, es decir, detectar todos los casos de fraude sin perder ninguno, la Precisión baja mucho. Esto sucede porque aparecen muchos falsos positivos.

7. Decisión final de ingeniería

Imaginando que formo parte del equipo técnico del banco, la política de decisión que recomendaría sería la siguiente:

Para proteger el banco de los fraudes, se ha decidido elegir una **política conservadora** descartando el umbral por defecto (0.5) y fijando el umbral de clasificación operativo en $\tau^* = 0{,}05$. El objetivo es maximizar la Sensibilidad (*Recall*) del modelo para garantizar la detección de fraudes, asumiendo una reducción en la Especificidad, es decir, un mayor número de bloqueos preventivos sobre transacciones legítimas (falsos positivos).
Esta decisión se basa en:

- **El coste asociado a los falsos positivos y falsos negativos:** Existe una gran diferencia económica. Un falso negativo (dejar pasar un fraude) supone una pérdida de 200 €, siendo 20 veces más perjudicial que un falso positivo (bloqueo erróneo de 10 €). Por lo tanto, la política del modelo debe centrarse en mitigar exclusivamente los errores financieros críticos.

- **El umbral que minimiza el coste total:** Según los cálculos de la tarea 3, el umbral de 0.05 es el punto óptimo que reduce el riesgo económico del banco al mínimo que es de 2920 €, lo que supone un ahorro significativo en comparación con los 4410 € que generaban con un umbral de 0.5.

- **El equilibrio entre seguridad y molestias para el cliente:** Reducir el umbral incrementa la tasa de falsos positivos (bloqueo erróneo de transacciones legítimas). No obstante, el análisis basado en la matriz de costes demuestra que el impacto económico de un falso negativo (fraude no detectado) es veinte veces superior, en consecuencia, minimizar este riesgo es muy importante al ajustar el modelo."

- **La interpretación conjunta de las curvas ROC y Precision-Recall:** La curva ROC nos muestra un modelo casi perfecto (AUC de 0.8442) ya que detecta muy bien los casos legítimos, pero oculta el impacto real de los falsos positivos. Sin embargo, la curva Precision-Recall (AP de 0.6551) se centra

en los fraudes, mostrando el problema que tenemos. Este tipo de gráfica demuestra que para lograr recuperar todos los fraudes (alto *Recall*), es necesario sacrificar la *Precision* y permitir que salten avisos falsos.

8. Conclusiones

Con esta práctica hemos aprendido que, en problemas del mundo real, **no todos los errores tienen el mismo impacto**. Evaluar un modelo únicamente con métricas globales como la exactitud puede resultar engañoso, especialmente en escenarios con clases muy desbalanceadas, como la detección de fraudes. Un alto porcentaje de aciertos en la clase mayoritaria puede ocultar fallos críticos en la clase minoritaria.

Además el umbral de decisión por defecto (0.5) no es un valor fijo, sino una **decisión de diseño** que debe adaptarse al contexto del problema. Al modificarlo, controlamos el equilibrio entre los Falsos Positivos y los Falsos Negativos, ajustando métricas como la Sensibilidad (*Recall*) y la Especificidad, para priorizar los errores más costosos o relevantes según el dominio.

En definitiva, entrenar un clasificador no consiste únicamente en optimizar sus métricas en un entorno controlado. El verdadero valor de un modelo debe evaluarse considerando el **coste y las consecuencias reales** de las decisiones que genera al ponerlo en producción. Por eso, en dominios donde los errores tienen costes muy diferentes, herramientas como la matriz de costes y las curvas Precisión-Recuperación son fundamentales para asegurar que el sistema sea seguro, útil y viable desde el punto de vista ecónomico.

Bibliografía

[1] Sebastián Ventura and Christian Luna. Práctica 4 - clasificación y el valor del error (diapositivas), 2026. Asignatura: Introducción al Aprendizaje Automático. Accedido en abril 2026.

[2] Universidad de Córdoba. Guion práctica 4: Clasificación y el valor del error (matriz de costes), 2026. Asignatura: Introducción al Aprendizaje Automático (3ª Ingeniería Informática). Curso 2025/2026. Accedido en abril 2026.

[3] Sebastián Ventura Soto. Tema 07 - evaluación de clasificadores (diapositivas de teoría), 2026. Asignatura: Introducción al Aprendizaje Automático. Accedido en abril 2026.

[4] Sebastián Ventura Soto. Tema 05b - clasificación logística (diapositivas de teoría), 2026. Asignatura: Introducción al Aprendizaje Automático. Accedido en abril 2026.