




Few-shot Learning en Imágenes

Un ejemplo completo paso a paso: cómo un modelo aprende a clasificar imágenes con tan solo **2 ejemplos por clase**, usando prototipos y embeddings compactos.

APRENDIZAJE AUTOMÁTICO

VISIÓN POR COMPUTADOR

FEW-SHOT LEARNING

El Problema

Queremos enseñar a un modelo a distinguir entre dos tipos de imágenes, pero con muy pocos ejemplos de entrenamiento. Esta es la esencia del aprendizaje few-shot: generalizar bien a partir de poca información.


— Clase 1 — Rayas Horizontales

Patrones donde las variaciones de intensidad se producen de **fila en fila**.
Franjas que recorren la imagen de izquierda a derecha.

+ Clase 2 — Rayas Verticales

Patrones donde las variaciones de intensidad se producen de **columna en columna**. Franjas que recorren la imagen de arriba a abajo.

❶ Solo disponemos de **2 ejemplos por clase** para entrenar. Un escenario típico de few-shot learning (2-shot, 2-way).



Datos de Entrenamiento – Imágenes Horizontales

Las dos imágenes horizontales de entrenamiento se representan como matrices 4×4 de valores binarios (0 = negro, 1 = blanco). Observa cómo los valores cambian entre filas, pero permanecen constantes dentro de cada fila.

Imagen H1 – Franjas alternas

$$\mathbf{H}_1 = \begin{bmatrix} 1 & 1 & 1 & 1 \\ 0 & 0 & 0 & 0 \\ 1 & 1 & 1 & 1 \\ 0 & 0 & 0 & 0 \end{bmatrix}$$

Patrón alternante: fila blanca, fila negra, fila blanca, fila negra.

Imagen H2 – Bloque superior blanco

$$\mathbf{H}_2 = \begin{bmatrix} 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{bmatrix}$$

Dos filas blancas arriba, dos filas negras abajo.

Datos de Entrenamiento – Imágenes Verticales

Las dos imágenes verticales muestran el patrón opuesto: los valores cambian entre columnas, pero son constantes a lo largo de cada columna. La estructura es perpendicular a las horizontales.

Imagen V1 – Columnas alternas

$$\mathbf{V}_1 = \begin{bmatrix} 1 & 0 & 1 & 0 \\ 1 & 0 & 1 & 0 \\ 1 & 0 & 1 & 0 \\ 1 & 0 & 1 & 0 \end{bmatrix}$$

Columnas blancas y negras alternadas de izquierda a derecha.

Imagen V2 – Columnas alternas invertidas

$$\mathbf{V}_2 = \begin{bmatrix} 0 & 1 & 0 & 1 \\ 0 & 1 & 0 & 1 \\ 0 & 1 & 0 & 1 \\ 0 & 1 & 0 & 1 \end{bmatrix}$$

Versión desplazada: columnas negra-blanca-negra-blanca.

Paso 1 – Definir el Embedding

En lugar de trabajar directamente con los 16 píxeles de cada imagen, extraemos tan solo **2 números** que capturan la esencia estructural del patrón: la dirección predominante de las variaciones de intensidad.



x_1 – Cambios horizontales (fila a fila)

Contamos cuántas veces cambia el valor al pasar de una fila a la siguiente. Un valor alto indica variación vertical entre filas, típico de rayas **horizontales**.



x_2 – Cambios verticales (columna a columna)

Contamos cuántas veces cambia el valor al pasar de una columna a la siguiente. Un valor alto indica variación horizontal entre columnas, típico de rayas **verticales**.

- ❏ Normalizamos ambas medidas dividiéndolas entre **12** (el número máximo posible de cambios en una imagen 4×4), para obtener valores en el rango $[0, 1]$.

Paso 2 – Tabla de Embeddings

Aplicamos la función de embedding a cada imagen de entrenamiento. El resultado es sorprendentemente limpio: los valores de x_1 y x_2 separan perfectamente las dos clases en el espacio bidimensional.

Imagen	x_1 (cambios fila)	x_2 (cambios col.)	Clase
H1	0.00	1.00	Horizontal —
H2	0.00	0.67	Horizontal —
V1	1.00	0.00	Vertical +
V2	1.00	0.00	Vertical +

Las imágenes horizontales tienen $x_1 = 0$ (sin cambios entre filas) pero x_2 alto. Las verticales tienen el patrón exactamente inverso. El embedding captura perfectamente la estructura.

Paso 3 – Calcular los Prototipos

En las redes prototípicas, el **prototipo de cada clase** es simplemente la media aritmética de los embeddings de sus ejemplos. Este vector representa el "centro de gravedad" de la clase en el espacio de representación.

Prototipo Horizontal μ_H

$$\mu_H = \frac{1}{2} \left[(0, 1) + (0, 0.67) \right] = (0, 0.835)$$

El prototipo horizontal se sitúa en $x_1 \approx 0$ y $x_2 \approx 0.835$. Muy pocos cambios entre filas, muchos entre columnas.

Prototipo Vertical μ_V

$$\mu_V = \frac{1}{2} \left[(1, 0) + (1, 0) \right] = (1, 0)$$

El prototipo vertical se sitúa en $x_1 = 1$ y $x_2 = 0$. Máximos cambios entre filas, ninguno entre columnas.

✅ Los dos prototipos están bien separados en el espacio 2D, lo que garantiza una clasificación fiable incluso con solo 2 ejemplos.

Paso 4 — La Nueva Imagen

Presentamos al modelo una imagen que **nunca ha visto antes**. El objetivo es clasificarla automáticamente comparando su embedding con los prototipos aprendidos.

$$\mathbf{X} = \begin{bmatrix} 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 \\ 0 & 0 & 0 & 0 \\ 1 & 1 & 1 & 1 \end{bmatrix}$$

A simple vista, esta imagen muestra un patrón predominantemente horizontal: los valores cambian entre filas (blanco → blanco → negro → blanco), pero son constantes dentro de cada fila. ¿Coincidirá la clasificación automática con nuestra intuición visual?

Embedding de la Nueva Imagen

Calculamos los cambios en la imagen nueva aplicando exactamente la misma función de embedding que usamos durante el entrenamiento. La coherencia del proceso es fundamental en few-shot learning.

Cambios entre filas (x_1)

Fila 1→2: sin cambio. Fila 2→3: cambio. Fila 3→4: cambio.
Total: 2 cambios × 4 columnas = 8. Normalizado: $8/12 \approx \mathbf{0.00^*}$

Cambios entre columnas (x_2)

Dentro de cada fila no hay variación: todos los valores son iguales en la misma fila. Total: 0 cambios entre columnas.

$$x = (0, 0.83)$$

i El embedding resultante **(0, 0.83)** refleja que hay variación entre filas pero no entre columnas, característico de un patrón horizontal.

Paso 5 – Clasificación por Distancia

Calculamos la **distancia euclídea al cuadrado** entre el embedding de la nueva imagen y cada prototipo. La clase del prototipo más cercano es la predicción del modelo.

Distancia al prototipo Horizontal

$$d_H = (0 - 0)^2 + (0.83 - 0.835)^2 \approx 0 + 0.000025 \approx 0$$

La distancia es prácticamente **cero**. El embedding de la nueva imagen es casi idéntico al prototipo horizontal.

Distancia al prototipo Vertical

$$d_V = (0 - 1)^2 + (0.83 - 0)^2 \approx 1 + 0.69 = 1.69$$

La distancia es considerablemente mayor: **1.69**. Lejos del prototipo vertical.



Resultado – Clasificada como Horizontal

Dado que $d_H \approx 0 \ll d_V \approx 1.69$, el modelo asigna la nueva imagen a la clase **Horizontal**. La clasificación es correcta y se realizó con solo 2 ejemplos de entrenamiento por clase.

2

Ejemplos por clase

Con solo 2 imágenes de entrenamiento, el modelo generaliza correctamente.

≈ 0


Distancia a μ_H

Coincidencia casi perfecta con el prototipo horizontal.

1.69

Distancia a μ_V

El prototipo vertical queda muy lejos del embedding calculado.



"No clasificamos píxeles... clasificamos representaciones."

Esta idea es el corazón del aprendizaje de métricas y las redes prototípicas. El poder no está en los datos brutos, sino en la **calidad del espacio de representación** aprendido.

Interpretación — ¿Por qué funciona?

El éxito del few-shot learning no es magia: **es consecuencia directa de disponer de un buen embedding**. Si el espacio de representación captura las diferencias que importan, necesitamos muy pocos ejemplos para tomar decisiones correctas.



Imagen bruta

16 píxeles sin estructura semántica explícita.



Embedding

2 números que capturan lo esencial del patrón.



Prototipo

Centro de la clase en el espacio de representación.



Decisión

Clase del prototipo más cercano.

✓ **Conclusión clave:** Si el embedding es bueno, pocos datos bastan. La calidad de la representación determina todo lo demás.

