ESCUELA POLITÉCNICA
SUPERIOR DE CÓRDOBA
Universidad de Córdoba

Introducción al Aprendizaje Automático

Grado en Ingeniería Informática

Práctica 6: Clasificación de Texto y Filtros Anti-Spam (Naïve Bayes)

Autores:

Alicia Muriel Fernández
Lucía Cañero Moslero

Octubre, 2026

UNIVERSIDAD
D
CÓRDOBA

Índice general

Índice de figuras **2**

1. Práctica 6: Clasificación de Texto y Filtros Anti-Spam **3**
1. Preprocesamiento y Representación Numérica del Texto 3
1.1. Exploración y Balanceo 3
1.2. El modelo Bag of Words (BoW) 4
2. Fundamentos del Clasificador Naïve Bayes 4
3. El Papel Crítico del Suavizado de Laplace 5
4. Evaluación del Modelo y Análisis de Errores 7
5. Inspección del Modelo: Palabras Clave del Spam 8
6. Reto: Evaluación con Mensajes Inventados 9
7. Conclusiones: Ventajas y Limitaciones 10

Bibliografía **12**

Alicia Muriel Fernández
Lucía Cañero Moslero

Índice de figuras

1. Matriz de confusión sobre el conjunto de test (1393 registros). 7

Alicia Muriel Fernández
Lucía Cañero Moslero

Capítulo 1

Práctica 6: Clasificación de Texto y Filtros Anti-Spam

Objetivo

Implementar y evaluar un clasificador de texto basado en **Naïve Bayes Multinomial** para distinguir automáticamente entre mensajes legítimos (*ham*) y correo no deseado (*spam*), familiarizándonos con el preprocesamiento de texto (Bolsa de Palabras o *Bag of Words*) y la interpretación de probabilidades.

1. Preprocesamiento y Representación Numérica del Texto

1.1. Exploración y Balanceo

El dataset presenta la siguiente distribución de clases:

Clase	Frecuencia	Porcentaje (%)
ham	4825	86.60 %
spam	747	13.40 %

Análisis de balanceo y métricas: Al ejecutar el código de esta práctica hemos generado la tabla de arriba y comprobado que el conjunto de datos presenta un desbalanceo considerable. De los 5572 mensajes, 4825 corresponden a la clase mayoritaria (*ham*, 86,60 %) y 747 a la clase minoritaria (*spam*, 13,40 %). En el clasificador Naïve Bayes, esta distribución corresponde a una **probabilidad a priori** muy alta de que un mensaje sea legítimo ($P(ham) = 0,866$), ya que esta probabilidad se define como la proporción global de ambas clases en el conjunto de entrenamiento.

Alicia Muriel Fernández
Lucía Cañero Moslero

Debido a este desequilibrio, evaluar el modelo basándose únicamente en la **exactitud (*accuracy*)** resulta engañoso e insuficiente. Por ejemplo, al igual que un sistema médico puede reflejar un 99 % de acierto simplemente diagnosticando a todos los pacientes como "sanos" (fallando en los casos reales de enfermos), un clasificador que marcara por defecto todos los correos como *ham* lograría una exactitud base del 86,60 %, a pesar de ser totalmente incapaz de detectar el *spam*.

Para evitar esto, es necesario evaluar el modelo combinando las medidas de **Precisión** (porcentaje de ejemplos correctamente clasificados como positivos) y ***Recall*** o Sensibilidad (porcentaje de ejemplos positivos reales que han sido detectados). Para ello utilizaremos la **medida F1**, que calcula la media armónica entre ambas magnitudes. Esta métrica es la más apropiada para estimar la calidad real del modelo, garantizando que los aciertos masivos en la clase mayoritaria no enmascaren los errores cometidos sobre el *spam*.

1.2. El modelo Bag of Words (BoW)

En problemas de clasificación, los algoritmos no pueden procesar texto crudo, por lo que es necesario transformarlo previamente en una representación numérica. Para ello, se utiliza la técnica *Bag of Words*, que convierte los mensajes en una matriz documento-término. En esta representación matemática:

- **Cada fila** representa un mensaje individual del conjunto de datos.
- **Cada columna** representa una palabra única del vocabulario total extraído (7383 términos).
- **Cada valor (celda)** indica la frecuencia absoluta, es decir, cuántas veces aparece esa palabra en ese mensaje en concreto.
- **Información perdida:** Al realizar esta transformación, se pierde el **orden exacto de las palabras** y su contexto. El algoritmo no construye una gramática ni entiende el significado profundo del mensaje, sino que restringe su análisis a la representación numérica basada estrictamente en el recuento y la frecuencia de cada término.

2. Fundamentos del Clasificador Naïve Bayes

El funcionamiento de este clasificador no se basa en memorizar mensajes completos de forma exacta, sino en aprender los patrones probabilísticos del vocabulario. Para tomar una decisión, el clasificador combina dos conceptos estadísticos:

- **Probabilidad a priori ($P(C)$):** Representa la proporción global de mensajes *spam* y *ham* en el conjunto de entrenamiento, es decir, indica la probabilidad de que un mensaje pertenezca a una clase antes de observar ninguna palabra. En nuestro caso, la distribución de los datos hace que la probabilidad a priori de recibir un mensaje legítimo sea muy alta ($P(ham) = 0,866$).
- **Probabilidad condicional ($P(W|C)$):** Mide la probabilidad de encontrar una palabra concreta sabiendo, de antemano, a qué clase pertenece el mensaje. Por ejemplo, evaluar P("gratis"|spam) permite medir la frecuencia que aparece esa palabra en los mensajes de spam. Si un mensaje contiene muchas palabras con alta probabilidad condicional en *spam*, la probabilidad de que sea fraudulento crece rápidamente.

¿Por qué el modelo recibe el nombre de "Naïve" (Ingenuo)?

En el lenguaje natural, las palabras no están aisladas, sino que mantienen relaciones gramaticales, semánticas y contextuales entre sí. Modelar matemáticamente todas estas dependencias de cada palabra que compone un mensaje resultaría un proceso y computacionalmente muy costoso.
Para evitarlo, el clasificador asume la **hipótesis de independencia condicional**. Esto significa que el algoritmo supone, de forma "ingenua", que, dada la clase, la presencia de una palabra es independiente de cualquier otra. Sabemos que esta suposición no se cumple en la realidad del lenguaje, pero tratar el problema como si las palabras fueran independientes permite multiplicar directamente sus probabilidades individuales.
La gran ventaja de esta simplificación es que permite construir un clasificador muy rápido de entrenar y eficaz en la práctica, incluso sin modelar todas las dependencias reales del lenguaje.

3. El Papel Crítico del Suavizado de Laplace

El problema de la frecuencia cero: En el clasificador Naïve Bayes, la probabilidad de un mensaje dada una clase se calcula como el producto de las probabilidades de cada palabra en esa clase, siguiendo la fórmula:

$$P(mensaje \mid C) = \prod_{i=1}^{n} P(x_i \mid C)$$

Cada $P(x_i \mid C)$ se estima a partir de la frecuencia relativa de la palabra x_i en los documentos de entrenamiento de la clase C. Si una palabra nunca aparece en los mensajes de una clase (por ejemplo, la palabra "oferta" no aparece en ningún ham del en-

Alicia Muriel Fernández
Lucía Cañero Moslero

trenamiento), entonces su probabilidad condicional será cero: $P(''oferta'' \mid ham) = 0$

Al multiplicar, cualquier producto que incluya ese factor se convierte en cero, independientemente de las demás palabras. Esto significa que cualquier mensaje que contenga "oferta" tendría probabilidad cero de ser ham, incluso si el resto del mensaje es totalmente legítimo. Esto es claramente un problema, porque una palabra nueva o rara no debería anular toda la evidencia.

Solución: Para evitar estos ceros, se utiliza el **Suavizado de Laplace**. Esta técnica consiste en añadir una pequeña corrección (normalmente 1) a todos los conteos de palabras, como si cada palabra hubiera aparecido una vez más de lo observado. La fórmula corregida para la probabilidad de una palabra x en la clase C es:

$$P(x \mid C) = \frac{count(x, C) + \alpha}{\sum_{v \in V}(\text{count}(v, C) + \alpha)} = \frac{count(x, C) + \alpha}{N_C + \alpha * |V|}$$

donde: *count(x,C)* es el número de veces que aparece x en documentos de clase C, N_C es el total de palabras en la clase C, |V| es el tamaño del vocabulario y α es el parámetro de suavizado =1 (suavizado de Laplace estándar). Con esto, una palabra que no ha sido vista en el entrenamiento tendrá una probabilidad pequeña pero no nula.

$$P(''oferta'' \mid ham) = \frac{0 + 1}{N_{ham} + 1 * |V|} > 0$$

De esta forma, el modelo se vuelve mucho más robusto ante vocabulario no visto en el entrenamiento, permitiéndole tomar su decisión apoyándose de forma segura en las demás palabras.

Pregunta específica - ¿Qué ocurre con la palabra "oferta" si no apareció en el entrenamiento?: como se ha mencionado anteriormente, si no utilizamos el suavizado de Laplace $P(''oferta'' \mid ham) = 0$, por muchas otras palabras normales que tenga el mensaje, si contiene la palabra "oferta" la probabilidad será 0. El clasificador no podría asignar nunca la clase ham a ese mensaje. Sin embargo, si usamos el suavizado se Laplace con α=1, la probabilidad de "oferta" en la clase ham será aproximadamente $\frac{1}{N_{ham}+|V|}$ (valor muy pequeño). Esto permite que el mensaje pueda clasificarse como ham si el resto de palabras aportan la evidencia suficiente.

Ejemplo numérico: Tras ejecutar nuestro código obtenemos que el vocabulario tiene 7383 palabras distintas. Si apareciera "oferta" en un mensaje de prueba, con $\alpha = 1$ su probabilidad sería: $P(''oferta'' \mid ham) = \frac{1}{N_{ham}+7383}$. Este valor será pequeño, pero no nulo, por lo que podrá combinar esta probabilidad con la de las demás palabras.

Alicia Muriel Fernández
Lucía Cañero Moslero

4. Evaluación del Modelo y Análisis de Errores

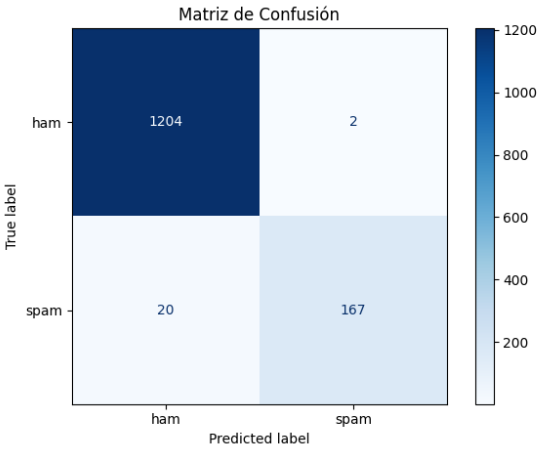


Figura 1: Matriz de confusión sobre el conjunto de test (1393 registros).

Métricas obtenidas:

Clase	Precisión	Recall	F1-score	Soporte
ham	0.98	1.00	0.99	1206
spam	0.99	0.89	0.94	187

- Accuracy: 0.98

Interpretación de los errores:

- **Falsos negativos (FN) - spam clasificado como ham:** 20 mensajes de spam no fueron detectados y llegaron a la bandeja de entrada del usuario.
- **Falsos positivos (FP) - ham clasificado como spam:** 2 mensajes legítimos fueron marcados erróneamente como spam. Esto significa que el modelo bloqueó 2 mensajes reales que no deberían haber sido filtrados.

Error más molesto en un filtro real: En un filtro de spam real el error que más molesta es un falso positivo, es decir, que se bloquee un mensaje válido. Esto conlleva varias consecuencias:
- Pérdida de información relevante: un correo legítimo puede contener datos importantes del trabajo, banco o de un familiar. Si se bloquea, el usuario corre el riesgo de no recuperarlo.

Alicia Muriel Fernández
Lucía Cañero Moslero

- Frustración del usuario: si los falsos positivos son frecuentes, el usuario pierde confianza en el filtro, empieza a revisarlo manualmente o termina desactivándolo.
- Coste: permitir que pase un spam solo causa la molestia de borrarlo, mientras que perder un mensaje importante puede acarrear graves problemas.

Análisis del comportamiento del modelo: El modelo detecta el 89 % de los correos no deseados (spam) y deja escapar el 11 % restante, algo que podría mejorarse con más datos o ajustando el umbral de decisión. Cuando el modelo señala que un mensaje es spam, acierta el 99 % de las veces, lo que demuestra que es muy fiable. En cuanto a los correos legítimos, solo 2 de todos ellos fueron clasificados incorrectamente, por lo que la cobertura es prácticamente perfecta.

En conjunto, el modelo es excelente, ya que bloquea muy pocos mensajes buenos, aunque todavía deja pasar algo de spam. En un sistema real, se podría reducir el umbral para atrapar más spam, pero eso aumentaría los falsos positivos. Dado que el spam filtrado tiene un costo bajo, la configuración actual es aceptable.

5. Inspección del Modelo: Palabras Clave del Spam

Analizando la diferencia de log-probabilidades, extraemos las 5 palabras que el modelo considera más indicativas de que un mensaje pertenezca a la clase *spam*:

	Palabra	$\log P(W\|\text{spam})$	$\log P(W\|\text{ham})$	**Diferencia**
1	claim	-5.476609	-10.903605	5.426995
2	prize	-5.772074	-10.903605	5.131531
3	150p	-5.979713	-10.903605	4.923892
4	tone	-6.193287	-10.903605	4.710317
5	500	-6.320039	-10.903605	4.583566

Interpretación de los resultados: Al analizar las palabras con mayor relevancia estadística, se aprecia que palabras como *claim*, *prize*, *150p* o *500* poseen un claro tono promocional y económico.
Estos resultados son completamente esperables para una tarea de detección de spam, ya que reflejan las tácticas que suelen usarse en estafas o premios fraudulentos.

Al examinar estos resultados, podemos entender cómo funciona el clasificador. Al analizar las palabras que se han seleccionado, podemos hacer varias cosas: Primero, **verificar la coherencia del modelo**: las palabras seleccionadas resultan lógicas para una persona, lo que genera confianza en que el modelo capta patrones reales y no ruido. Segundo, **corregir errores**: si aparecen términos extraños o sin sentido, eso nos indica que hay un problema en el preprocesamiento o en los datos. Tercero,

Alicia Muriel Fernández
Lucía Cañero Moslero

justificar las predicciones: se puede explicar por qué un mensaje se clasificó como spam, por ejemplo, porque incluía claim y prize. Y cuarto, **perfeccionar el sistema**: ante falsos positivos, es posible añadir esas palabras a una lista de excepciones o modificar el suavizado.

6. Reto: Evaluación con Mensajes Inventados

Para poner a prueba el clasificador, se diseñaron tres mensajes (uno neutro, uno claramente nocivo y uno ambiguo) y se evaluó la respuesta probabilística del modelo en cada caso:

1. **Mensaje claramente *ham*:** *"Hey, let me know when you finish work so we can grab dinner."*
   Predicción: ham ($P(ham) \approx 100,0\,\% \mid P(spam) \approx 0,0\,\%$).
2. **Mensaje claramente *spam*:** *"URGENT! Your bank account has been locked. Click here to verify your details and claim a 1000$ cash prize."*
   Predicción: spam ($P(spam) \approx 100,0\,\% \mid P(ham) \approx 0,0\,\%$).
3. **Mensaje ambiguo:** *"Can you please review the attached document with the new business offer?"*
   Predicción: ham ($P(ham) \approx 76,04\,\% \mid P(spam) \approx 23,96\,\%$).

Respuestas a las cuestiones planteadas:

- **¿Coincide la predicción del modelo con lo que esperabas?**
  Sí, los resultados encajan con lo previsto. Los dos primeros mensajes, que representan casos extremos, por lo que el modelo los clasifica con total seguridad. En cambio, el mensaje ambiguo, que cualquier persona podría interpretar como un correo legítimo, pero incluye un término promocional. Por eso, el modelo reduzca su confianza hasta el 76 %.
- **¿En qué caso parece estar más seguro?**
  El modelo está seguro ya que le asigna una probabilidad casi del 100 % tanto en el mensaje claramente *ham* como en el claramente *spam*. En el caso del mensaje fraudulento, la probabilidad que le asigna se debe a que contiene varias palabras muy características, como claim, prize o URGENT. Durante el entrenamiento, el clasificador aprendió que estas palabras tienen una probabilidad condicional altísima de pertenecer a la clase minoritaria(spam). Al multiplicarse entre sí, siguiendo el principio de independencia de Naïve Bayes, hace que el modelo se decante por la clase *spam*.

Alicia Muriel Fernández
Lucía Cañero Moslero

- **¿Qué características del mensaje ambiguo podrían explicar la duda del modelo?**
  La distribución (76 % vs 24 %) muestra perfectamente el impacto de la **hipótesis Naïve y del enfoque Bag of Words**. Por un lado, la palabra *offer* incrementa de forma significativa la sospecha de que el mensaje pertenece a spam. Sin embargo, al utilizar la representación *Bag of Words*, el algoritmo evalúa cada término de forma independiente y es incapaz de interpretar cómo las palabras funcionan juntas dentro de un correo corporativo.

  El resto de las palabras (*review, attached, document, business*) son muy habituales en correos legítimos, y además la **probabilidad a priori** de la clase *ham* es mayoritaria ($P = 0,866$). Por eso, se inclina hacia ham. No obstante, el término sospechoso *offer* penaliza drásticamente la confianza final del modelo, impidiendo que alcance el 100 % de los casos anteriores.

7. Conclusiones: Ventajas y Limitaciones

Tras desarrollar y evaluar nuestro filtro anti-spam, la principal lección que hemos aprendido es que no se necesita un algoritmo muy complejo para obtener buenos resultados en un problema real de clasificación de texto.

En la práctica, la mayor **ventaja** de Naïve Bayes es su rapidez tanto en el entrenamiento como en la predicción. A diferencia de los modelos de "caja negra": si miramos el modelo, podemos ver exactamente qué palabras (como *prize* o *claim*) están influyendo en la decisión. Aunque el algoritmo no entiende de gramática ni de significados profundos, ha demostrado ser muy bueno detectando las frecuencias y tácticas habituales.

Sin embargo, al implementar este clasificador también hemos observado algunos **inconvenientes**. El cuello de botella más evidente es su propia naturaleza "ingenua" (la hipótesis *Naïve*) y el uso de la matriz *Bag of Words*. Al separar las frases y asumir que cada palabra es independiente del resto, el modelo se vuelve completamente "ciego" al contexto y pierde el orden exacto de las palabras. Esto explica por qué el clasificador dudó tanto con nuestro mensaje inventado corporativo: no sabe interpretar una frase en su conjunto, solo sumar evidencias aisladas.

Adicionalmente, hemos visto lo delicado que resulta encadenar probabilidades. Sin el suavizado de Laplace, la aparición de una sola palabra nueva en el conjunto de test habría introducido un cero en las cuentas, estropeando predicciones que, por lo demás, eran bastante intuitivas.

En resumen, Naïve Bayes sigue siendo una opción excelente como modelo base gracias a su bajo coste computacional y a lo fácil que es interpretarlo. No obstante, al basarse únicamente en contar frecuencias y asumir que las palabras son indepen-

Alicia Muriel Fernández
Lucía Cañero Moslero

dientes entre sí, el algoritmo es incapaz de entender la gramática o el significado profundo del texto. Es un filtro ideal para estafas evidentes, pero se quedaría bastante corto en sistemas que necesiten interpretar el contexto o el doble sentido de una conversación.

Alicia Muriel Fernández
Lucía Cañero Moslero

Bibliografía

[1] Sebastián Ventura & Christian Luna. Introducción al aprendizaje automático: Teoría para la práctica 6 - probabilidad, teorema de bayes y naïve bayes, 2026. URL https://moodle.uco.es/m2526/pluginfile.php/404574/mod_resource/content/2/Diapositivas-P6.pdf. Material docente. Universidad de Córdoba. Accedido en abril 2026.

[2] Sebastián Ventura & Christian Luna. Introducción al aprendizaje automático: Práctica 6: Clasificación de texto y filtros anti-spam (naïve bayes), 2026. URL https://moodle.uco.es/m2526/pluginfile.php/404573/mod_resource/content/1/Guion-P6.pdf. Material docente. Universidad de Córdoba. Accedido en abril 2026.

[3] FasterCapital. Suavizado de Laplace: Suavizado de los bordes - Suavizado de Laplace en Naïve Bayes, 2024. URL https://fastercapital.com/es/contenido/Suavizado-de-Laplace--Suavizado-de-los-bordes--Suavizado-de-Laplace-en-Naive-Bayes.html. Accedido en abril 2026.

[4] Sebastián Ventura Soto. Tema 07 - Evaluación de clasificadores (diapositivas de teoría), 2026. Asignatura: Introducción al Aprendizaje Automático. Accedido en abril 2026.

[5] Sebastián Ventura Soto. Tema 04 - Ajuste fino y selección de modelos (diapositivas de teoría), 2026. Asignatura: Introducción al Aprendizaje Automático. Accedido en abril 2026.

[6] E. Kavlakoglu. £Qué son los clasificadores Naïve Bayes? ibm.com., (2025, noviembre 27). URL https://www.ibm.com/es-es/think/topics/naive-bayes. Accedido en abril 2026.