

Aprendizaje Activo: Ejemplo Completo Paso a Paso

Una guía práctica para entender cómo un modelo puede aprender de forma eficiente seleccionando inteligentemente qué datos necesita etiquetar, logrando resultados sólidos con el mínimo esfuerzo posible.

Selección inteligente


El modelo elige qué ejemplos consultar

Pocas etiquetas

Aprender con datos etiquetados mínimos

Ejemplo numérico

Dos iteraciones completas detalladas



Motivación: ¿Por qué Aprendizaje Activo?

En proyectos reales de machine learning, etiquetar datos manualmente es uno de los procesos más costosos en tiempo y dinero. Disponemos de grandes volúmenes de datos sin etiquetar, pero anotar cada uno de ellos resulta inviable.

→ Etiquetar es costoso

Requiere expertos humanos, tiempo y presupuesto elevado para cada muestra anotada.

→ Datos sin etiquetar abundan

Tenemos enormes volúmenes de datos crudos que el modelo no puede aprovechar directamente.

→ El modelo pregunta lo mínimo

La clave es que el propio modelo decide qué ejemplos son más valiosos para consultar.

i Idea clave: El modelo aprende preguntando lo mínimo posible, centrándose en los ejemplos donde tiene más dudas.



Variables del Problema

Para ilustrar el proceso de aprendizaje activo, usamos un problema de clasificación de correos electrónicos: distinguir entre **Spam** y **No Spam**. El problema se describe mediante dos variables de entrada simples e interpretables.

Variables de entrada (features)

1

x_1

Número de **palabras sospechosas** en el correo (ej. "gratis", "oferta", "urgente")

2

x_2

Número de **enlaces** incluidos en el cuerpo del mensaje

Variable objetivo (clase)

Clase 0

 **No Spam** – Correo legítimo

Clase 1

 **Spam** – Correo no deseado

 A mayor número de palabras sospechosas y enlaces, mayor probabilidad de Spam.

Datos Iniciales Etiquetados

El proceso comienza con un conjunto etiquetado muy pequeño: solo **4 ejemplos**. Esto simula una situación realista en la que apenas disponemos de muestras anotadas para entrenar el modelo inicial.

Ejemplo	x ₁ (palabras sospechosas)	x ₂ (enlaces)	Clase
L1	1	0	 No Spam
L2	2	0	 No Spam
L3	3	1	 Spam
L4	4	1	 Spam

 Con tan solo 4 ejemplos, el modelo tiene información muy limitada. El aprendizaje activo permitirá mejorarlo de forma eficiente sin necesidad de anotar todos los datos disponibles.

Pool de Datos No Etiquetados

Disponemos de **8 ejemplos sin etiquetar** que forman el *pool* de candidatos. El modelo debe analizar todos ellos para decidir cuál merece ser consultado al experto humano (oráculo). Solo se pedirá la etiqueta del ejemplo más informativo.

Ejemplo	x_1	x_2
U1	0	1
U2	1	2
U3	2	2
U4	3	2
U5	4	2
U6	5	2
U7	2	3
U8	3	3

¿Cómo elige el modelo?

En lugar de pedir etiquetas para los 8 ejemplos, el aprendizaje activo utiliza una **estrategia de selección basada en incertidumbre**: el modelo identifica el punto donde menos seguro está de su predicción.

 Este enfoque permite ahorrar hasta un **70-90%** del coste de etiquetado en problemas reales.

Modelo Inicial: Regresión Logística

El modelo de partida es una **regresión logística**, entrenada únicamente con los 4 ejemplos etiquetados. Combina linealmente las variables de entrada y transforma el resultado con la función sigmoide para obtener probabilidades.

Función lineal (z)

$$z = -4 + 0.8 \cdot x_1 + 1.2 \cdot x_2$$

Combina las características con pesos aprendidos del conjunto etiquetado inicial.

Probabilidad de Spam

$$P(\text{Spam}) = \sigma(z) = \frac{1}{1 + e^{-z}}$$

La función sigmoide transforma cualquier valor de z en una probabilidad entre 0 y 1.


- ❑ Cuanto más cerca esté $P(\text{Spam})$ de **0.5**, más incierto está el modelo sobre ese ejemplo.

Iteración 1: Probabilidades del Modelo

Aplicamos el modelo inicial a todos los ejemplos del pool no etiquetado. Para cada punto calculamos $z = -4 + 0.8 \cdot x_1 + 1.2 \cdot x_2$ y obtenemos $P(\text{Spam}) = \sigma(z)$. Buscamos el valor más cercano a 0.5.

Ejemplo	x1	x2	P(Spam)
U1	0	1	0.06
U2	1	2	0.31
U3	2	2	0.50
U4	3	2	0.69
U5	4	2	0.83
U6	5	2	0.92
U7	2	3	0.77
U8	3	3	0.88

Interpretación visual



Selección por Incertidumbre

La estrategia de muestreo más común en aprendizaje activo es la **selección por incertidumbre** (*uncertainty sampling*): se elige el ejemplo para el que el modelo es menos seguro en su predicción.

Criterio de selección

Elegir el punto con **P(Spam) más cercano a 0.5**. En ese umbral, el modelo asigna igual probabilidad a ambas clases: máxima incertidumbre.

Ejemplo seleccionado

U3 $\rightarrow$ P(Spam) = 0.50

U3 tiene exactamente un 50% de probabilidad de ser Spam. Es el punto donde el modelo no sabe qué decidir.

¿Por qué no otro?

U1 (0.06) y U6 (0.92) son predicciones muy seguras. Etiquetarlos aportaría poca información nueva al modelo.

- ✓ Seleccionando el punto de mayor incertidumbre, cada consulta al experto humano tiene el **máximo impacto** posible en el aprendizaje del modelo.

Consulta al Oráculo

En aprendizaje activo, el **oráculo** es la fuente de conocimiento que proporciona etiquetas verdaderas: normalmente un experto humano, un sistema externo o una base de datos de referencia. El modelo le presenta el ejemplo más incierto y recibe su etiqueta real.

Consulta enviada

El modelo solicita la etiqueta del ejemplo **U3** ($x_1=2$, $x_2=2$), el de mayor incertidumbre.

Respuesta del oráculo

El experto analiza el correo correspondiente y determina: **U3 = Spam**.

Integración al modelo

El ejemplo etiquetado **U3 → Spam** se añade al conjunto de entrenamiento y se elimina del pool.



Nuevo Conjunto Etiquetado

Tras la primera consulta, el conjunto de entrenamiento crece de **4 a 5 ejemplos**. Aunque el incremento parece pequeño, el ejemplo añadido (U3) fue seleccionado por ser el más informativo, por lo que su impacto en el modelo es desproporcionadamente grande.

Ejemplo	x1	x2	Clase	Origen
L1	1	0	 No Spam	Original
L2	2	0	 No Spam	Original
L3	3	1	 Spam	Original
L4	4	1	 Spam	Original
U3	2	2	 Spam	Nuevo (iteración 1)

 El conjunto etiquetado ahora incluye un ejemplo con **x2=2**, lo que permite al modelo aprender mejor el peso de los enlaces en la clasificación de Spam.

Modelo Actualizado

Con el nuevo conjunto de 5 ejemplos etiquetados, reentrenamos la regresión logística. Los parámetros del modelo cambian para reflejar la nueva información aprendida de U3.

Modelo anterior

$$z = -4 + 0.8 \cdot x_1 + 1.2 \cdot x_2$$

Entrenado con 4 ejemplos. Los pesos iniciales tenían menos información sobre la influencia de los enlaces.

Modelo actualizado

$$z = -3.6 + 0.9 \cdot x_1 + 1.1 \cdot x_2$$

Entrenado con 5 ejemplos. Cambios clave tras incorporar U3:

- El sesgo sube de -4 a -3.6 (umbral de decisión más bajo)
- El peso de x_1 aumenta: las palabras sospechosas pesan más
- El peso de x_2 disminuye levemente: los enlaces se ajustan

Iteración 2: Nuevas Probabilidades

Aplicamos el modelo actualizado al pool restante de **7 ejemplos** (U3 ya fue etiquetado y eliminado). Volvemos a buscar el punto de máxima incertidumbre para realizar la segunda consulta.

Ejemplo	P(Spam) – Iter. 1	P(Spam) – Iter. 2
U1	0.06	0.08
U2	0.31	0.38
U4	0.69	0.79
U5	0.83	0.90
U6	0.92	0.96
U7	0.77	0.82
U8	0.88	0.92

Evolución del modelo

El modelo actualizado es más decisivo: las probabilidades se alejan más del 0.5 en la mayoría de ejemplos, lo que indica mayor **confianza** en sus predicciones gracias al nuevo ejemplo etiquetado.

📌 U2 sigue siendo el más incierto con P=0.38, aunque el modelo ya tiene algo más de claridad que en la iteración anterior.

Nueva Selección: Iteración 2

Con las probabilidades actualizadas, aplicamos de nuevo el criterio de máxima incertidumbre. Entre todos los ejemplos restantes del pool, identificamos aquel cuya probabilidad predicha está más cerca del umbral de decisión del 50%.

U1 $\rightarrow$ P = 0.08

Muy probable que sea No Spam. El modelo está bastante seguro. Baja incertidumbre.

★ **U2 $\rightarrow$ P = 0.38**

El más cercano a 0.5 de todos los restantes. **Máxima incertidumbre: seleccionado.**

U4-U8 $\rightarrow$ P $\geq$ 0.79

Todos tienen probabilidades altas de ser Spam. El modelo está bastante seguro en estos casos.

✓ **Conclusión:** U2 ($x_1=1$, $x_2=2$) es el punto más incierto restante y será consultado al oráculo en esta segunda iteración.

Segunda Consulta al Oráculo

El modelo presenta el ejemplo **U2** ($x_1=1$, $x_2=2$) al experto humano. A pesar de tener 2 enlaces, solo contiene 1 palabra sospechosa, lo que genera ambigüedad en la clasificación automática.



Consulta: Ejemplo U2

Correo con 1 palabra sospechosa y 2 enlaces. El modelo duda: $P(\text{Spam}) = 0.38$. ¿Es spam o no?




Respuesta del oráculo

El experto revisa el mensaje y determina: **U2 = No Spam**. Un enlace legítimo con poco vocabulario sospechoso.



Impacto esperado

Esta etiqueta ayudará al modelo a distinguir que tener enlaces no es suficiente por sí solo para clasificar como Spam. El contexto importa.



Conjunto Final tras Dos Iteraciones

Tras dos rondas de aprendizaje activo, el conjunto etiquetado ha crecido de 4 a **6 ejemplos**, incorporando exactamente los dos puntos más informativos del pool. El modelo ahora tiene ejemplos que cubren mejor el espacio de decisión.

Ejemplo	x ₁	x ₂	Clase	Origen
L1	1	0	 No Spam	Original
L2	2	0	 No Spam	Original
L3	3	1	 Spam	Original
L4	4	1	 Spam	Original
U3	2	2	 Spam	Iteración 1
U2	1	2	 No Spam	Iteración 2

-  Con solo **2 consultas adicionales** al oráculo, el modelo ha aprendido a diferenciar casos ambiguos donde el número de enlaces es alto pero las palabras sospechosas son bajas.

Idea Clave del Proceso

El ciclo de aprendizaje activo revela un principio fundamental: un modelo que sabe *dónde* tiene dudas puede dirigir su propio proceso de aprendizaje de manera mucho más eficiente que si recibiera datos al azar.




Aprende donde tiene dudas

El modelo identifica su frontera de decisión e interroga al oráculo exactamente en esos puntos ambiguos.




Reduce incertidumbre

Cada consulta estratégica desplaza la frontera de decisión hacia una zona más precisa, aumentando la confianza global del modelo.



Mejora con pocos datos

El resultado es un modelo más preciso con un número mínimo de etiquetas, reduciendo drásticamente el coste de anotación.



Conclusiones

El aprendizaje activo transforma la forma en que pensamos sobre los datos de entrenamiento: no todos los ejemplos aportan el mismo valor, y elegir bien cuáles etiquetar es una ventaja competitiva enorme.



No todos los datos son iguales

Un ejemplo en la frontera de decisión puede valer más que cien ejemplos fáciles de clasificar.



Selección informativa

El aprendizaje activo selecciona activamente los ejemplos más informativos, maximizando el aprendizaje por cada etiqueta obtenida.



Reduce el coste de etiquetado

Menos consultas al experto significa menos tiempo, menos dinero y proyectos de ML más viables en contextos con datos escasos.

Mensaje final: Aprender mejor no es usar más datos. Es usar los datos *adecuados*.