




Tema 14: Eficiencia en el etiquetado y datos limitados

Aprendizaje automático con recursos escasos: semi-supervised, active and few-shot learning

BLOQUE INTRODUCTORIO

INTRODUCCIÓN

Eficiencia en el etiquetado y datos limitados

¿Por qué el etiquetado es el verdadero cuello de botella?

En aprendizaje automático supervisado asumimos que disponemos de datos etiquetados en abundancia. Pero en la práctica, **el verdadero reto no es conseguir datos, sino conseguir etiquetas**. Este bloque explora cómo superar esa limitación con estrategias inteligentes.

📌 👉 El problema no es el dato, es la etiqueta

El aprendizaje supervisado clásico


Formulación estándar

- Dataset: pares $(\mathbf{x}_i, y_i)$
- Objetivo: aprender $\mathbf{f}(\mathbf{x}) \rightarrow y$
- Supuesto implícito: suficientes datos etiquetados


El problema

Este es un modelo **idealizado**. En proyectos reales, disponer de grandes volúmenes de datos etiquetados de calidad es la excepción, no la norma.

⚠ Este supuesto rara vez se cumple en la práctica



El cuello de botella: el etiquetado



Imágenes

Requieren **anotación manual** píxel a píxel o bounding boxes. Costoso y lento.



Medicina

Cada etiqueta requiere **diagnóstico experto**. Escaso y caro de obtener.



Texto

La **interpretación semántica** exige comprensión profunda del contexto.

⊗ Etiquetar es caro, lento y difícil — los datos abundan, las etiquetas escasean

¿Qué pasa cuando hay pocas etiquetas?

Consecuencias directas

Sobreajuste


El modelo memoriza los pocos ejemplos disponibles en lugar de generalizar.

Poca robustez

Modelos frágiles ante variaciones pequeñas en los datos de entrada.

Mala generalización

Alto error en datos nuevos, no vistos durante el entrenamiento.



El rendimiento depende directamente de la cantidad y calidad de la supervisión

Nuevos enfoques del aprendizaje

Antes

«Entrenar con muchos datos etiquetados»

Ahora

- ¿Cómo aprovechar datos **no etiquetados**?
- ¿Qué datos merece la pena **etiquetar**?
- ¿Cómo aprender con **pocos ejemplos**?

📌 👉 El problema es de eficiencia, no de cantidad



Aprendizaje con pocos datos y pocos ejemplos

Tres grandes estrategias permiten superar la escasez de etiquetas, cada una con una lógica diferente de aprovechar la información disponible.



Semi-supervisado

Usar datos **no etiquetados** para mejorar el modelo entrenado con pocos etiquetados.



Active Learning

Elegir **qué datos etiquetar** de forma inteligente para maximizar el aprendizaje.



Few-shot Learning

Aprender con **poquísimos ejemplos** transfiriendo conocimiento previo.




👉 Tres estrategias, tres formas de usar la información

Tres enfoques, tres ideas

Enfoque	Idea central	Recurso clave
Semi-supervisado	Aprovechar datos no etiquetados	Estructura de $p(x)$
Active Learning	Optimizar qué datos etiquetar	Criterio de selección
Few-shot Learning	Transferir conocimiento previo	Representación aprendida

✔️ 👉 No compiten entre sí — se complementan y pueden combinarse



Aprendizaje semisupervisado

Aprovechando datos no etiquetados

¿Y si pudiéramos extraer información útil de los datos que *no* tienen etiqueta? El aprendizaje semisupervisado hace exactamente eso: combina un pequeño conjunto etiquetado con un gran conjunto sin etiquetar para mejorar el rendimiento del modelo.



👉 No todo el conocimiento viene de las etiquetas

Escenario típico

Los dos conjuntos

- **L** – datos etiquetados (pequeño)
- **U** – datos no etiquetados (grande)

En la práctica: **$IUI \gg ILI$**

La pregunta clave

Si **U** no tiene etiquetas, ¿puede contribuir al aprendizaje del modelo? La respuesta es sí – siempre que se cumplan ciertos supuestos sobre la estructura de los datos.

  ¿Podemos usar **U** para mejorar el modelo?

¿Sirven los datos sin etiqueta?

Lo que NO tienen

No contienen **y**. No nos dicen directamente cuál es la clase correcta.

Lo que SÍ tienen

Contienen **estructura**: cómo se distribuyen los datos, qué regiones del espacio están pobladas, dónde hay fronteras naturales.


✓ 👉 La distribución de los datos $p(x)$ aporta información sobre $p(y|x)$

La estructura de los datos

Principio fundamental

Si conocemos cómo se distribuye $\mathbf{p}(\mathbf{x})$, podemos inferir algo sobre $\mathbf{p}(\mathbf{y}|\mathbf{x})$: la forma del espacio de entrada guía las decisiones de clasificación.

$$p(x) \Rightarrow p(y|x)$$



📌 Los datos no etiquetados guían dónde trazar la frontera de decisión

¿Cuándo funciona el semisupervisado?

El aprendizaje semisupervisado no es mágico: solo mejora el modelo si la distribución de los datos cumple ciertos supuestos.

1

Suavidad

Puntos cercanos tienen etiquetas similares.

2

Cluster

Los datos forman grupos naturales y cada grupo corresponde a una clase.

3

Manifold

Los datos de alta dimensión viven en una variedad de baja dimensión.

⚠️ 👉 Sin supuestos válidos, los datos no etiquetados pueden perjudicar al modelo

Smoothness Assumption (Suavidad)

La idea

Si dos puntos $\mathbf{x}$ y $\mathbf{x}'$ son **cercanos** en el espacio de entrada, sus etiquetas deben ser **similares**. Esto implica que la función de decisión varía suavemente: no hace saltos bruscos en regiones densas.


- Puntos próximos $\rightarrow$ misma clase
- Función de decisión **continua**

Consecuencia

Los datos no etiquetados en zonas densas refuerzan la frontera de decisión aprendida con los datos etiquetados.

  La proximidad implica similitud

Cluster Assumption



La idea

- Los datos forman **grupos naturales** (clusters)
- Cada cluster corresponde a **una sola clase**
- La frontera de decisión debe pasar por **zonas poco densas**

Si hay pocos puntos entre dos clusters, es razonable colocar ahí la frontera.

📌 👉 La frontera evita regiones densas de datos

Manifold Assumption

El supuesto

- Datos de alta dimensión viven en una **variedad de baja dimensión**
- Las etiquetas cambian suavemente **a lo largo del manifold**

Implicación práctica

La distancia euclidiana en el espacio original puede ser engañosa. Lo que importa es la **geometría intrínseca** de los datos: dos puntos alejados en el espacio pueden estar muy cercanos sobre el manifold.



👉 Importa la geometría, no solo la distancia

Cómo usar datos no etiquetados



Modelos generativos

Modelan $p(x, y)$ combinando etiquetados y no etiquetados.



Métodos de grafos

Propagan etiquetas a través de un **grafo de similitud**.



Consistencia

El modelo debe dar **predicciones estables** ante perturbaciones.



Pseudo-labeling

El modelo genera **etiquetas propias** para los datos no etiquetados.



Veremos en detalle la estrategia más simple: pseudo-labeling

Pseudo-labeling: la idea básica

01

Entrenar con L

Construir un modelo inicial con el conjunto etiquetado disponible.

02

Predecir en U

Aplicar el modelo a los datos no etiquetados y obtener predicciones.

03

Seleccionar ejemplos seguros

Filtrar solo las predicciones con alta confianza.

04


Reentrenar

Ampliar L con los pseudo-etiquetados seleccionados y repetir.



👉 El modelo genera sus propias etiquetas — aprendizaje auto-reforzado

Ciclo de pseudo-labeling



El proceso es **iterativo**: en cada ronda, el conjunto etiquetado L crece con ejemplos de alta confianza extraídos de U . El modelo se vuelve progresivamente más robusto con cada ciclo, siempre que los pseudo-labels seleccionados sean correctos.

¿Qué ejemplos usamos?

No todas las predicciones sobre U son fiables. Solo incorporamos al conjunto etiquetado los ejemplos que superan un **umbral de confianza**.

Probabilidad alta

$\max P(y|x) > \text{umbral}$: el modelo asigna una clase con probabilidad muy alta.

Margen alto

Gran diferencia entre la primera y la segunda clase más probable.

Baja entropía

La distribución de probabilidades está concentrada, no dispersa.

✅ 👉 Solo los ejemplos «seguros» entran al nuevo conjunto etiquetado

Por qué funciona el pseudo-labeling

Ventajas principales

- **Aprovecha** datos no etiquetados existentes
- **Escalable**: funciona con grandes volúmenes de U
- **Fácil** de implementar sobre cualquier clasificador

En la práctica

Con un buen umbral de confianza y un modelo inicial razonablemente bueno, el pseudo-labeling puede mejorar significativamente el rendimiento sin necesidad de etiquetas adicionales de un experto humano.



👉 Mucho rendimiento con poco coste

Problema principal: confirmation bias

Propagación de errores

Si el modelo inicial comete un error, ese error se etiqueta con alta confianza y **entra al conjunto de entrenamiento**, reforzando el error en la siguiente ronda.

Confirmation bias (sesgo de confirmación)


El modelo tiende a confirmar sus propias predicciones previas. Las regiones donde ya se equivoca se vuelven **cada vez más difíciles de corregir**.

❌ 🖱️ Un error en el modelo inicial puede amplificarse de forma acumulativa

Ejemplo conceptual de pseudo-labeling



En la primera iteración, la frontera de decisión es **aproximada**. Al añadir ejemplos de alta confianza de U, el modelo ajusta mejor esa frontera. El proceso se repite, **reforzando lo que ya sabe** y explorando gradualmente zonas más inciertas.



Idea clave del semisupervisado

Datos no etiquetados aportan

La estructura de $p(x)$ guía la frontera de decisión aunque no haya etiquetas.

Solo bajo condiciones

Los supuestos de suavidad, cluster y manifold deben cumplirse.

La estructura de los datos guía el aprendizaje


ACTIVE LEARNING

Active Learning

Aprender eligiendo qué datos etiquetar

En lugar de etiquetar datos al azar, Active Learning propone que el propio modelo **decida qué ejemplos necesita ver** para aprender más rápido y con menos esfuerzo humano.

  No todos los datos valen lo mismo para el aprendizaje



Active Learning

Aprender qué datos etiquetar



👉 No todos los datos valen lo mismo

El problema del etiquetado



Caro

Contratar expertos o plataformas de anotación tiene un coste elevado por ejemplo.



Lento

Anotar miles de ejemplos manualmente puede llevar semanas o meses.



Requiere expertos

En dominios especializados (medicina, derecho), solo ciertos perfiles pueden etiquetar correctamente.



No podemos etiquetar todo — hay que ser selectivos

Nueva pregunta

Enfoque clásico

«¿Cómo entrenamos mejor el modelo dado un dataset fijo?»

Enfoque Active Learning

«¿Qué datos debemos etiquetar para que el modelo aprenda más rápido?»

El cambio de perspectiva es radical: en lugar de recibir pasivamente los datos, el **modelo participa activamente** en la construcción de su propio conjunto de entrenamiento.

  El modelo decide qué aprender



Principio de Active Learning

Observación clave

Algunos ejemplos aportan **mucha información** al modelo, otros son redundantes o ya conocidos.

La estrategia

Seleccionar solo los ejemplos **más informativos** para enviarlos al oráculo (experto humano).



👉 Aprender con menos datos, pero mejores — mayor eficiencia por etiqueta

Planteamiento del escenario

L – Etiquetados

Conjunto **pequeño** de ejemplos con etiqueta conocida. Suficiente para un modelo inicial.

U – No etiquetados


Conjunto **grande** de ejemplos candidatos a etiquetar. Pool de selección.

Oráculo

Experto humano que proporciona etiquetas fiables cuando el modelo le **consulta**.

La clave es la interacción entre el modelo y el oráculo: el modelo **selecciona**, el oráculo **etiqueta**.

Ciclo de Active Learning




El proceso es **interactivo e iterativo**: en cada ciclo, el modelo mejora y su selección de ejemplos se vuelve más sofisticada. El objetivo es maximizar el rendimiento minimizando el número de consultas al oráculo.

¿Dónde preguntar?

La intuición

Los ejemplos **cerca de la frontera de decisión** son los más útiles: el modelo duda entre clases y necesita supervisión para corregirse.

Los ejemplos lejos de la frontera ya están clasificados con seguridad — etiquetarlos no añade información nueva.



📌 Los puntos dudosos son los más informativos



Selección por incertidumbre

La estrategia más común en Active Learning: seleccionar los ejemplos donde el modelo **muestra mayor incertidumbre** en sus predicciones. Si el modelo duda, eso significa que necesita más información en esa región del espacio.



👉 Preguntar donde no sabemos — la incertidumbre guía la selección

Medida 1: menor confianza

Fórmula

$$1 - \max_y P(y|x)$$

Interpretación

Si la probabilidad máxima asignada a alguna clase es baja, el modelo no está seguro de ninguna.

En la práctica

- Seleccionar ejemplos donde **max P(y|x)** es pequeño
- Alta incertidumbre = alejado de cualquier clase
- Simple y efectivo para clasificación binaria



👉 Baja probabilidad máxima → alta incertidumbre

Medida 2: margen mínimo

Fórmula

$$P(y_1|x) - P(y_2|x)$$

Diferencia entre la primera y segunda clase más probable.

Interpretación

- Margen **pequeño** → dos clases casi igual de probables
- El modelo no sabe cuál elegir
- Más informativo que la menor confianza en clasificación multiclase

📌 Clases muy cercanas en probabilidad = ejemplo muy informativo

Medida 3: entropía

La idea

La entropía mide la **dispersión de la distribución** de probabilidades sobre todas las clases.

$$H = - \sum_y P(y|x) \log P(y|x)$$

Interpretación

- **Alta entropía** → probabilidades distribuidas uniformemente → mucha duda
- **Baja entropía** → una clase claramente dominante → certeza
- Medida más completa en problemas multiclase



👉 Distribución plana = máxima incertidumbre

Más allá de la incertidumbre



Diversidad

Seleccionar ejemplos **diversos** entre sí para evitar etiquetar puntos muy similares (redundantes). Cubre mejor el espacio de entrada.



Query by Committee

Entrenar varios modelos distintos. Los ejemplos donde **los modelos discrepan** entre sí son los más informativos.



👉 La diversidad complementa la incertidumbre — evita redundancia en las consultas

Por qué usar Active Learning

↓90%

Menos etiquetas

En benchmarks estándar, Active Learning puede alcanzar el mismo rendimiento con una fracción de los datos etiquetados.

↑ROI

Más eficiencia

Cada consulta al oráculo aporta el máximo valor posible al modelo.

↑F1

Mejor rendimiento

Al centrarse en los ejemplos difíciles, el modelo mejora en las zonas más críticas.

✓ 👉 Más rendimiento con menos coste de anotación

Limitaciones del Active Learning

Necesita experto disponible

El oráculo debe estar accesible de forma interactiva durante el ciclo de entrenamiento, lo que no siempre es viable.

Depende del modelo inicial

Si el primer modelo es muy malo, su criterio de selección será pobre y guiará mal las primeras consultas.

Puede sesgar los datos

Seleccionar siempre los ejemplos más inciertos puede concentrar los datos etiquetados en zonas fronterizas, ignorando otras regiones.

⚠️ ➡️ Active Learning no es automático — requiere diseño cuidadoso

Active Learning vs Semisupervisado

Dimensión	Semisupervisado	Active Learning
Estrategia	Usar datos sin etiquetar	Elegir qué etiquetar
Interacción humana	Mínima	Interactiva (oráculo)
Recurso clave	Estructura de $p(x)$	Criterio de selección
Coste de etiquetado	Sin coste adicional	Reducido pero presente

✔️ 👉 Dos enfoques complementarios — pueden combinarse



Idea clave del bloque

No todos los datos son iguales

Algunos ejemplos aportan mucha más información al modelo que otros.

Elegir bien mejora el aprendizaje

Una selección inteligente de ejemplos a etiquetar supera a la selección aleatoria.

Aprender mejor preguntando mejor

FEW-SHOT & ZERO-SHOT

Few-shot y Zero-shot Learning

Aprender con pocos... o con ningún ejemplo

¿Qué ocurre cuando no hay tiempo ni recursos para recopilar datos? Few-shot y Zero-shot Learning representan el **límite extremo** de la eficiencia en el aprendizaje: generalizar con mínima o nula supervisión directa.

📌 👉 ¿Podemos aprender sin datos? La respuesta sorprende

Few-shot y Zero-shot Learning

**Aprender con
pocos... o con
ningún
ejemplo**



📌 🙋 ¿Podemos aprender sin datos?

Nuevas clases, pocos datos

El escenario habitual

- Aparecen **clases nuevas** que el modelo no ha visto
- Disponemos de muy **pocos ejemplos** por clase
- A veces, **ningún ejemplo** directo

Ejemplos reales

- Enfermedades raras: pocos casos clínicos
- Nuevos productos: sin histórico de ventas
- Especies poco frecuentes: escasas muestras

❌ 👉 El modelo debe adaptarse rápido a situaciones no vistas durante el entrenamiento



Limitación del aprendizaje clásico

Muchos ejemplos por clase

El modelo supervisado tradicional necesita cientos o miles de ejemplos por clase para aprender representaciones robustas.

Desde cero cada vez

Cada nueva clase requiere un nuevo ciclo de entrenamiento completo. No transfiere el conocimiento acumulado sobre otras clases.




👉 El aprendizaje clásico no escala a nuevos escenarios con pocos datos

Nuevo enfoque: aprender a comparar

El cambio de paradigma

- No aprender **clases específicas**
- Aprender **representaciones** ricas
- Luego **comparar** en ese espacio



📄 👉 Aprender a comparar, no a memorizar — la clave del few-shot



Few-shot Learning

Pocos ejemplos por clase

Típicamente **1 a 5 ejemplos** por clase nueva. Se denomina *k-shot* cuando hay k ejemplos.

Conocimiento previo

El modelo ha aprendido previamente una **representación general** sobre muchas clases distintas. Ese conocimiento se transfiere.



Generalizar con pocos datos gracias al conocimiento previo

Espacio de representación

Embeddings

$$f(x) \rightarrow z$$

Una red neuronal **f** transforma cada entrada en un vector **z** en un espacio de baja dimensión. La clave: puntos similares quedan **próximos** en ese espacio.

- Similaridad = proximidad vectorial
- Clases distintas → regiones separadas

 Sedán rojo	[0.82, 0.79, 0.11, 0.85, 0.76]
 Hatchback azul	[0.80, 0.81, 0.09, 0.83, 0.78]
 SUV verde	[0.84, 0.77, 0.12, 0.86, 0.74]
 Moto roja	[0.21, 0.18, 0.88, 0.15, 0.22]
 Moto negra	[0.19, 0.20, 0.91, 0.13, 0.24]
 Moto amarilla	[0.23, 0.17, 0.87, 0.16, 0.20]

Los vectores de coches son similares entre sí; los de motos también, pero ambos grupos son claramente distintos.



Lo importante es la **calidad del espacio aprendido**

Clasificación por prototipos

La idea

- Cada clase tiene un **prototipo**: el centroide de sus embeddings
- Clasificar un punto nuevo: calcular su **distancia** a cada prototipo
- Asignar la clase del prototipo **más cercano**

Ventaja

Añadir una clase nueva es tan simple como **calcular su prototipo** con los k ejemplos disponibles. No se necesita reentrenamiento.

- ✓ Comparar con el «representante» de cada clase

Ejemplo sencillo de clasificación

Datos de soporte

Clase	Ejemplos	Prototipo
Clase A	(1,2), (2,2)	(1.5, 2)
Clase B	(5,5), (6,5)	(5.5, 5)

Nuevo punto

Punto a clasificar: **(3,3)**

Cálculo

- $d((3,3), \text{prototipo A}) \approx 1.8$
- $d((3,3), \text{prototipo B}) \approx 3.2$

El punto (3,3) se asigna a **Clase A** por ser el prototipo más cercano.

✅ 👉 Clasificación por distancia – sencillo y eficaz



¿Y si no hay ningún ejemplo?

Few-shot

Disponemos de **k ejemplos** por clase nueva (con k pequeño). Calculamos prototipos y clasificamos por distancia.

Zero-shot

Cero ejemplos de la clase nueva. ¿Cómo clasificar sin haber visto ningún dato? Aquí entra el conocimiento **semántico**.



👉 Zero-shot es el caso extremo — el límite del aprendizaje

Zero-shot Learning

La clave

- **Sin ejemplos** de la clase nueva
- Se apoya en **conocimiento externo**: atributos, descripciones, texto
- El conocimiento **sustituye** a los datos

¿Cómo es posible?

Si el modelo ha aprendido a relacionar conceptos en un espacio semántico compartido, puede inferir dónde estaría una clase nueva **sin haber visto ningún ejemplo** de ella.

  Aprender sin ver datos — posible gracias al espacio semántico



Reconocer una cebra sin haberla visto

El escenario

- El modelo **nunca ha visto** una cebra en entrenamiento
- Pero sabe: «**caballo + rayas negras y blancas**»
- El atributo «rayas» está representado en el espacio semántico

El resultado

Combinando los conceptos conocidos, el modelo puede **construir una representación** de «cebra» y reconocerla cuando la ve, sin haberla visto antes.

✓ 👉 El conocimiento semántico sustituye a los datos directos

Ejemplo moderno: imagen + texto



Imagen → embedding

Texto → embeddings

Similitud coseno → etiqueta

Modelos como **CLIP** aprenden un espacio compartido entre imágenes y texto. Para clasificar, simplemente se compara el embedding de la imagen con los embeddings de descripciones textuales («perro», «gato», «coche») — sin ningún reentrenamiento adicional.

✅ 👉 Nuevas clases en tiempo real, solo con una descripción de texto

Few-shot vs Zero-shot

Dimensión	Few-shot	Zero-shot
Ejemplos	Pocos (1–5 por clase)	Ninguno
Base del aprendizaje	Datos de soporte	Conocimiento semántico
Mecanismo	Distancia a prototipos	Espacio semántico compartido
Flexibilidad	Alta	Máxima
Requisito previo	Representación rica	Descripción de la clase

 Dos formas de generalizar — ambas se apoyan en conocimiento previo



Mensaje clave del bloque

Aprender con pocos datos

Few-shot Learning demuestra que unos pocos ejemplos bastan cuando la representación es rica.

Aprender sin datos

Zero-shot Learning muestra que el conocimiento semántico puede reemplazar completamente a los ejemplos directos.

Transferir conocimiento

En ambos casos, el valor está en lo que el modelo ya sabe, no en los datos nuevos.

La clave no es el dato, es la representación